

PREDIKSI ANGKA HARAPAN HIDUP (*LIFE EXPECTANCY*) MENGUNAKAN PENDEKATAN MACHINE LEARNING REGRESI



Disusun untuk memenuhi tugas terstruktur :

Mata kuliah : Machine Learning

Dosen : Lutfiah Maharani Siniwi, M.Stat.

DISUSUN OLEH :

- | | |
|----------------------------------|-------------|
| 1. Ardika Wahyu Fariz | (K1D024013) |
| 2. Meylina Nur Sasmita | (K1D024017) |
| 3. Fatih Maulana Luthf Rabbaanii | (K1D024022) |
| 4. Eunike Prasetyaning Yuniawan | (K1D024026) |
| 5. Armelda Shafa Wardhani | (K1D024029) |

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI

UNIVERSITAS JENDERAL SOEDIRMAN

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

PROGRAM STUDI STATISTIKA

PURWOKERTO

2026

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya, sehingga laporan project akhir mata kuliah Machine Learning yang berjudul "Prediksi Angka Harapan Hidup (Life Expectancy) Menggunakan Pendekatan Machine Learning Regresi" ini dapat diselesaikan dengan baik.

Laporan ini disusun sebagai pemenuhan tugas project akhir yang menggantikan/melengkapi Ujian Akhir Semester (UAS) pada mata kuliah Machine Learning Kelas A. Dalam penyusunan laporan ini, kami menerapkan seluruh alur kerja machine learning mulai dari eksplorasi data, prapemrosesan, pemodelan, hingga evaluasi dan interpretasi model.

Kami menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat kami harapkan demi perbaikan di masa mendatang. Kami juga mengucapkan terima kasih kepada dosen pengampu mata kuliah Machine Learning yang telah memberikan bimbingan dan arahan selama proses pengerjaan project ini.

Semoga laporan ini dapat memberikan manfaat dan menjadi bahan referensi yang berguna bagi pembaca.

Purwokerto, 26 Juni 2026

Penulis

BAB I

PENDAHULUAN

1.1 Latar Belakang

Angka harapan hidup (*life expectancy*) merupakan salah satu indikator penting dalam mengukur tingkat kesejahteraan dan kualitas hidup masyarakat. Indikator ini mencerminkan kondisi kesehatan penduduk sekaligus menggambarkan perkembangan sosial, ekonomi, dan pendidikan suatu negara. Meskipun secara global angka harapan hidup cenderung meningkat seiring kemajuan teknologi dan layanan kesehatan, akan tetapi masih terdapat perbedaan yang cukup besar antarnegara yang menunjukkan adanya ketimpangan dalam berbagai aspek pembangunan.

Oleh sebab itu, pemahaman mengenai faktor-faktor yang memengaruhi harapan hidup menjadi penting bagi pemerintah dan organisasi kesehatan dalam merumuskan kebijakan yang efektif. Harapan hidup dipengaruhi oleh berbagai faktor, antara lain tingkat kematian, prevalensi penyakit, kondisi ekonomi, pengeluaran kesehatan, serta tingkat pendidikan. Namun, hubungan antarvariabel tersebut sering kali bersifat kompleks sehingga sulit dijelaskan hanya dengan pendekatan statistik konvensional.

Perkembangan *machine learning* memberikan alternatif pendekatan yang mampu mempelajari pola hubungan antarvariabel secara lebih fleksibel. Berbagai metode *machine learning*, seperti Regresi Linear, Decision Tree, Random Forest, dan XGBoost dapat digunakan untuk membangun model prediksi harapan hidup berdasarkan data historis. Selain menghasilkan prediksi yang akurat, teknik interpretasi model seperti *feature importance* dan SHAP (*SHapley Additive exPlanations*) juga memungkinkan identifikasi faktor-faktor yang paling berpengaruh terhadap hasil prediksi.

Dalam penelitian ini digunakan dataset *Life Expectancy Data* yang memuat berbagai indikator kesehatan, ekonomi, dan sosial dari berbagai negara. Dataset ini dipilih karena memiliki keragaman variabel yang relevan dengan harapan hidup, serta mengandung tantangan nyata berupa *missing values* dan *outlier* yang umum ditemui dalam proses analisis data. Selain itu, variabel target berupa angka harapan hidup bersifat kontinu sehingga sesuai untuk dimodelkan menggunakan metode regresi.

Berdasarkan kondisi tersebut, diperlukan suatu pendekatan analisis data yang mampu mengidentifikasi faktor-faktor utama yang berkaitan dengan harapan hidup secara lebih objektif dan berbasis data. Oleh karena itu, penelitian ini memanfaatkan teknik *machine learning* pada dataset *Life Expectancy Data* untuk memperoleh model prediksi yang baik sekaligus memberikan pemahaman mengenai faktor-faktor yang berpengaruh terhadap angka harapan hidup.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Faktor-faktor apa yang paling berpengaruh terhadap angka harapan hidup berdasarkan dataset *Life Expectancy Data*?
2. Seberapa baik model regresi dapat memprediksi angka harapan hidup berdasarkan variabel yang tersedia dalam dataset?
3. Model regresi manakah yang memberikan performa terbaik di antara Regresi Linear, Decision Tree Regressor, Random Forest Regressor, dan XGBoost Regressor dalam memprediksi angka harapan hidup?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang ada, tujuan dari penelitian ini adalah:

1. Mengetahui faktor-faktor yang paling berpengaruh terhadap angka harapan hidup berdasarkan dataset *Life Expectancy Data*.
2. Mengukur kemampuan model regresi dalam memprediksi angka harapan hidup berdasarkan variabel-variabel yang tersedia dalam dataset.
3. Menentukan model regresi terbaik di antara Regresi Linear, Decision Tree Regressor, Random Forest Regressor, dan XGBoost Regressor dalam memprediksi angka harapan hidup.

1.4 Manfaat Penelitian

Hasil dari penelitian ini diharapkan dapat memberikan manfaat baik secara teoretis maupun praktis, sebagai berikut:

1. Manfaat Teoretis

- a. Pengembangan Ilmu Pengetahuan: Penelitian ini diharapkan dapat memperkaya khasanah ilmu pengetahuan, khususnya di bidang *data science*, *machine learning*, dan kesehatan masyarakat (*public health*) dalam memahami aplikasi algoritma regresi pada data demografi.
- b. Referensi Metodologi: Hasil perbandingan performa antar model (Linear, Decision Tree, Random Forest, dan XGBoost) dapat menjadi referensi dan dasar bagi peneliti lain dalam memilih metode yang tepat untuk studi prediktif serupa di masa mendatang.

2. Manfaat Praktis

- a. Bagi Pemerintah dan Pembuat Kebijakan: Memberikan wawasan berbasis data mengenai faktor-faktor dominan yang mempengaruhi harapan hidup. Hal ini dapat digunakan sebagai acuan dalam menyusun kebijakan prioritas di bidang kesehatan dan kesejahteraan masyarakat.
- b. Bagi Institusi Kesehatan: Menyediakan alat prediktif yang dapat digunakan untuk melakukan simulasi atau proyeksi angka harapan hidup, sehingga membantu dalam perencanaan alokasi sumber daya dan intervensi kesehatan yang lebih efektif.
- c. Bagi Praktisi Data: Memberikan pemahaman praktis tentang implementasi dari keempat model regresi dan *tuning hyperparameter*, serta bagaimana mengevaluasi kinerjanya secara objektif dalam kasus nyata (*real-world case*).

1.5 Batasan Penelitian

Penelitian ini memiliki beberapa batasan, yaitu:

1. Cakupan Data: Data yang digunakan adalah data sekunder dari dataset "Life Expectancy Data" yang diambil dari platform Kaggle. Data ini mencakup berbagai negara dengan periode waktu tertentu (2000-2015) dan tidak mencakup data terbaru.
2. Algoritma: Perbandingan model hanya terbatas pada empat algoritma regresi yaitu Linear Regression, Decision Tree, Random Forest, dan XGBoost.
3. Penanganan Data: Keputusan dalam penanganan *missing values* (menggunakan median) dan *outlier* (dibiarkan) didasarkan pada pertimbangan analisis awal dan dapat mempengaruhi hasil akhir.

4. Fitur yang Digunakan: Tidak semua fitur dalam dataset digunakan. Beberapa fitur dihapus berdasarkan alasan tertentu.

BAB II

TINJAUAN DATASET

2.1 Sumber Dataset

Nama Dataset: Life Expectancy Data

Sumber: Kaggle (<https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who>)

Data Primer: Global Health Observatory (GHO) data repository milik WHO

Data Pendukung: United Nations (UN)

Periode Data: Tahun 2000 s.d. 2015

Lisensi: Tersedia untuk publik (public domain)

2.2 Deskripsi Umum Dataset

Dataset yang digunakan dalam penelitian ini adalah Life Expectancy Data yang dikompilasi oleh WHO (*World Health Organization*) dan United Nations. Dataset ini berisi data statistik kesehatan, ekonomi, pendidikan, dan sosial dari 193 negara yang tercatat selama periode 16 tahun, yaitu dari tahun 2000 hingga 2015.

Dataset ini dipilih karena kelengkapan variabelnya yang mencakup berbagai aspek kehidupan yang secara teoritis berpengaruh terhadap angka harapan hidup. Selain itu, dataset ini telah banyak digunakan dalam penelitian bidang kesehatan dan machine learning, sehingga validitas dan relevansinya sudah teruji. Dataset memenuhi seluruh persyaratan minimal yang ditetapkan dalam tugas project ini, yaitu memiliki lebih dari 1000 observasi, lebih dari 5 kolom fitur, memuat campuran tipe data numerik dan kategorik, serta memiliki satu kolom target yang jelas.

2.3 Data Dictionary (Deskripsi Variabel)

Untuk memudahkan pemahaman terhadap dataset yang digunakan, berikut disajikan *data dictionary* yang memuat deskripsi setiap variabel, meliputi nama, tipe data, dan penjelasannya.

Tabel 2.1 Data Dictionary

No	Nama Variabel	Tipe	Deskripsi
1	Country	Kategorik	Nama negara
2	Year	Numerik	Tahun observasi (2000-2015)
3	Status	Kategorik	Status negara (Developed / Developing)
4	Life expectancy	Numerik kontinu	Harapan hidup saat lahir (tahun)
5	Adult Mortality	Numerik	Angka kematian dewasa (per 1000 populasi)
6	infant deaths	Numerik	Jumlah kematian bayi (per 1000 kelahiran)
7	Alcohol	Numerik	Konsumsi alkohol per kapita (liter)
8	percentage expenditure	Numerik	% pengeluaran kesehatan dari GDP
9	Hepatitis B	Numerik	Cakupan imunisasi Hepatitis B (%)
10	Measles	Numerik	Jumlah kasus campak
11	BMI	Numerik	Rata-rata Indeks Massa Tubuh
12	under-five deaths	Numerik	Jumlah kematian anak di bawah 5 tahun
13	Polio	Numerik	Cakupan imunisasi Polio (%)
14	Total expenditure	Numerik	Total pengeluaran kesehatan (% dari GDP)
15	Diphtheria	Numerik	Cakupan imunisasi Difteri (%)
16	HIV/AIDS	Numerik	Kematian akibat HIV/AIDS (per 1000 anak)
17	GDP	Numerik	Produk Domestik Bruto per kapita (USD)

18	Population	Numerik	Jumlah populasi
19	thinness 1-19 years	Numerik	Prevalensi ketipisan usia 1-19 tahun (%)
20	thinness 5-9 years	Numerik	Prevalensi ketipisan usia 5-9 tahun (%)
21	Income composition of resources	Numerik	Indeks komposisi pendapatan (0-1)

2.4 Variabel Target dan Variabel Fitur

Variabel target yang sesuai untuk dataset ini adalah *Life expectancy* (Angka Harapan Hidup). Variabel ini dipilih karena merupakan indikator utama kesejahteraan dan kesehatan suatu populasi. Variabel-variabel fitur adalah seluruh variabel lain dalam dataset (kecuali country dan year) yang digunakan untuk memprediksi variabel target. Penjelasan mengenai variabel disajikan dalam tabel berikut.

Tabel 2.2 Variabel Dataset

Jenis Variabel	Jumlah	Variabel
Target	1	Life expectancy
Prediktor	19	Status, Adult Mortality, infant deaths, Alcohol, percentage expenditure, Hepatitis B, Measles, BMI, under-five deaths, Polio, Total expenditure, Diphtheria, HIV/AIDS, GDP, Population, thinness 1-19 years, thinness 5-9 years, Income composition of resources, Schooling
Identitas	2	Country, Year

2.5 Jenis Masalah Machine Learning

Berdasarkan paradigma *supervised learning* (pembelajaran terawasi), permasalahan dalam penelitian ini diklasifikasikan secara spesifik sebagai persoalan regresi (*regression*

problem). Penentuan klasifikasi ini didasarkan secara fundamental pada sifat dari variabel target (dependen) yang akan diprediksi, yaitu *Life Expectancy* (Angka Harapan Hidup). Variabel target ini merupakan data numerik berskala kontinu (*continuous numerical variable*), yang artinya nilainya dapat bervariasi dalam rentang bilangan riil (misalnya, 65,3 tahun; 72,8 tahun; atau 80,1 tahun) dan tidak terbatas pada sejumlah kategori diskrit tertentu

Untuk membedakannya secara konseptual, dalam *machine learning*, terdapat dua jenis utama permasalahan prediksi berdasarkan variabel target:

1. Klasifikasi (*Classification*): Digunakan ketika variabel target bersifat kategorikal (*discrete*) atau bersifat nominal, seperti label "Hidup" vs "Mati", atau tingkat kategori "Rendah", "Sedang", "Tinggi". Tujuannya adalah untuk memprediksi kelas atau kelompok ke mana suatu data masuk.
2. Regresi (*Regression*): Digunakan ketika variabel target bersifat numerik kontinu, di mana tujuannya adalah untuk memprediksi suatu nilai kuantitatif yang memiliki makna ukuran atau besaran.

Karena *Life Expectancy* direpresentasikan dalam satuan tahun dengan potensi nilai pecahan (desimal) dan tidak memiliki batas kelompok klasifikasi yang baku, maka permasalahan ini secara tepat termasuk ke dalam kategori regresi. Konsekuensi dari penetapan klasifikasi ini secara langsung memengaruhi seluruh rangkaian metodologi yang digunakan, mulai dari pemilihan algoritma (keempat algoritma yang digunakan merupakan varian *regressor*: *Linear Regression*, *Decision Tree Regressor*, *Random Forest Regressor*, dan *XGBoost Regressor*), metrik evaluasi yang bersifat kontinu (MAE, MSE, RMSE, R^2), hingga teknik interpretasi hasil yang berorientasi pada estimasi nilai numerik. Dengan demikian, seluruh proses pemodelan pada penelitian ini dirancang untuk meminimalkan selisih antara nilai prediksi kontinu dan nilai aktual, bukan untuk memaksimalkan akurasi pelabelan kategori.

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian

Penelitian ini dilakukan melalui beberapa tahapan yang disusun secara sistematis untuk menghasilkan model prediksi yang optimal. Alur penelitian dimulai dari perumusan tujuan penelitian dan pengumpulan data, kemudian dilanjutkan dengan proses eksplorasi, persiapan data, pemodelan, hingga evaluasi model. Tahapan penelitian yang dilakukan adalah sebagai berikut:

1. Perumusan Tujuan dan Pengumpulan Data

Menentukan tujuan penelitian serta mengumpulkan data yang akan digunakan dalam proses analisis dan pemodelan.

2. Penelaahan Data (*Data Understanding*)

Melakukan pemahaman terhadap data melalui identifikasi tipe data, analisis statistik deskriptif, dan visualisasi data untuk mengetahui karakteristik serta pola yang terdapat dalam dataset.

3. Validasi Data

Memeriksa kualitas data untuk memastikan kesesuaian format, konsistensi nilai, dan kelengkapan data sebelum dilakukan analisis lebih lanjut.

4. Pembersihan Data (*Data Cleaning*)

Melakukan penanganan missing value, menghapus data duplikat, serta mendeteksi dan menangani outlier agar kualitas data menjadi lebih baik.

5. Analisis *Feature Importance* dan *SHAP*

Mengidentifikasi tingkat pengaruh masing-masing fitur terhadap variabel target menggunakan *Feature Importance* dan *SHAP* (*SHapley Additive exPlanations*). Hasil analisis digunakan sebagai dasar dalam seleksi fitur yang relevan.

6. Standardisasi Data

Melakukan standardisasi fitur numerik untuk menyamakan skala data sehingga proses pelatihan model dapat berjalan lebih optimal.

7. Penentuan Variabel X dan y

Menentukan variabel independen (X) sebagai fitur prediktor dan variabel dependen (y) sebagai target prediksi.

8. *Train-Test Split*

Membagi dataset menjadi data latih (*training set*) dan data uji (*testing set*) untuk keperluan pelatihan dan evaluasi model.

9. *Pemodelan Regresi*

Membangun model prediksi menggunakan empat algoritma regresi yang telah ditentukan untuk membandingkan performa masing-masing model.

10. *Evaluasi Model*

Mengevaluasi kinerja model menggunakan matrik evaluasi yang sesuai, seperti MAE, RMSE, dan R^2 , guna menentukan model dengan performa terbaik.

11. *Hyperparameter Tuning*

Melakukan optimasi parameter pada model terbaik yang diperoleh dari tahap evaluasi untuk meningkatkan akurasi dan performa prediksi.

3.2 Penelaahan Data (Eksplorasi Data)

1. **Identifikasi Tipe Data dan Statistik Deskriptif**

Tahap eksplorasi data diawali dengan mengidentifikasi struktur dan karakteristik dataset yang digunakan. Identifikasi dilakukan menggunakan fungsi `df.info()` untuk mengetahui jumlah data pada setiap kolom, tipe data yang dimiliki masing-masing variabel, serta jumlah nilai yang tidak kosong (*non-null*). Informasi ini penting untuk memastikan bahwa setiap variabel telah memiliki tipe data yang sesuai dan untuk mengidentifikasi adanya data yang hilang sebelum dilakukan analisis lebih lanjut.

Selanjutnya, analisis statistik deskriptif dilakukan menggunakan fungsi `df.describe()` pada seluruh variabel numerik. Hasil analisis ini memberikan gambaran umum mengenai karakteristik data melalui nilai jumlah data (*count*), rata-rata (*mean*), standar deviasi (*standard deviation*), nilai minimum, kuartil pertama (25%), median (50%), kuartil ketiga (75%), dan nilai maksimum. Informasi tersebut digunakan untuk memahami pola penyebaran data dan mendeteksi indikasi awal adanya nilai ekstrem.

Untuk variabel kategorik, yaitu Status, statistik deskriptif diperoleh menggunakan fungsi `df.describe(include='object')`. Analisis ini menampilkan jumlah data, banyaknya kategori yang tersedia, kategori yang paling sering muncul, serta frekuensi kemunculannya.

Hasil tersebut membantu dalam memahami komposisi data berdasarkan kategori negara berkembang (*Developing*) dan negara maju (*Developed*).

2. Visualisasi Data

Selain menggunakan statistik deskriptif, eksplorasi data juga dilakukan melalui berbagai visualisasi untuk memperoleh pemahaman yang lebih mendalam mengenai distribusi dan hubungan antarvariabel. Visualisasi pertama berupa bar chart pada variabel Status untuk melihat proporsi jumlah negara yang termasuk kategori *Developing* dan *Developed*. Grafik ini memberikan gambaran mengenai keseimbangan distribusi data berdasarkan status negara. Selanjutnya, dibuat histogram untuk seluruh variabel numerik guna melihat bentuk distribusi data pada masing-masing variabel. Melalui histogram dapat diketahui apakah data cenderung berdistribusi normal, miring ke kanan (*right-skewed*), atau miring ke kiri (*left-skewed*). Informasi ini menjadi pertimbangan dalam proses pembersihan dan transformasi data.

Untuk melihat penyebaran data dan mendeteksi keberadaan nilai ekstrem, dibuat boxplot pada seluruh variabel numerik. Visualisasi ini menunjukkan posisi median, rentang kuartil, serta titik-titik yang berada di luar rentang normal sehingga dapat digunakan sebagai indikasi awal adanya outlier. Selanjutnya, dilakukan pembuatan scatter plot antara setiap variabel numerik dengan variabel target, yaitu Life expectancy. Visualisasi ini bertujuan untuk melihat pola hubungan antara masing-masing variabel independen dengan target, baik berupa hubungan positif, negatif, maupun hubungan yang tidak menunjukkan pola tertentu. Terakhir, dibuat heatmap matriks korelasi untuk seluruh variabel numerik. Sebelum perhitungan korelasi dilakukan, variabel Status terlebih dahulu diubah ke bentuk numerik melalui proses encoding. Heatmap digunakan untuk melihat kekuatan hubungan antarvariabel serta mengidentifikasi variabel yang memiliki korelasi tinggi terhadap variabel target maupun antarvariabel independen.

3.3 Validasi Data

Validasi data dilakukan untuk memastikan bahwa dataset yang digunakan memiliki kualitas yang baik dan layak untuk dianalisis. Tahap ini dimulai dengan pemeriksaan data duplikat menggunakan fungsi `duplicated()`. Pemeriksaan tersebut bertujuan untuk mengetahui

apakah terdapat baris data yang tercatat lebih dari satu kali sehingga dapat memengaruhi hasil analisis.

Selanjutnya dilakukan pengecekan nilai yang hilang (*missing value*) pada setiap kolom menggunakan fungsi `isna().sum()`. Hasil pemeriksaan ini digunakan untuk menentukan langkah penanganan yang tepat terhadap data yang tidak lengkap.

Validasi juga dilakukan terhadap kemungkinan adanya nilai negatif pada variabel numerik. Pemeriksaan ini penting karena beberapa variabel dalam dataset secara logis tidak seharusnya memiliki nilai negatif. Dengan demikian, keberadaan nilai negatif dapat menjadi indikasi kesalahan pencatatan atau input data. Selain itu, dilakukan verifikasi dimensi dataset menggunakan fungsi `df.shape` untuk memastikan jumlah baris dan kolom yang digunakan selama proses analisis sesuai dengan data yang telah dikumpulkan. Hasil validasi ini menjadi dasar dalam menentukan langkah pembersihan data pada tahap berikutnya.

3.4 Pembersihan Data (*Data Cleaning*)

1. Penanganan *Missing Value*

Berdasarkan hasil validasi data, ditemukan beberapa variabel numerik yang masih memiliki nilai kosong (*missing value*), yaitu *Life expectancy*, *Adult Mortality*, *Alcohol*, *Hepatitis B*, *BMI*, *Polio*, *Total expenditure*, *Diphtheria*, *GDP*, *Population*, *thinness 1–19 years*, *thinness 5–9 years*, *Income composition of resources*, dan *Schooling*.

Untuk mengatasi permasalahan tersebut, dilakukan imputasi menggunakan nilai median pada masing-masing variabel. Metode ini dipilih karena median lebih stabil terhadap keberadaan outlier dibandingkan rata-rata (*mean*). Selain itu, berdasarkan hasil visualisasi histogram, beberapa variabel menunjukkan distribusi yang cenderung miring (*skewed*), sehingga median dianggap lebih mampu merepresentasikan nilai tengah data secara akurat. Dengan cara ini, seluruh data yang memiliki nilai kosong dapat diisi tanpa menghilangkan informasi yang tersedia pada baris data lainnya.

2. Penanganan Duplikasi

Setelah proses penanganan missing value selesai dilakukan, pengecekan data duplikat dilakukan kembali menggunakan fungsi `duplicated()`. Langkah ini bertujuan untuk memastikan bahwa tidak terdapat baris data yang berulang dan dapat memengaruhi hasil

analisis maupun proses pembentukan model. Berdasarkan hasil pemeriksaan, tidak ditemukan data duplikat pada dataset yang digunakan. Oleh karena itu, tidak diperlukan proses penghapusan data dan seluruh baris data tetap dipertahankan untuk tahap analisis berikutnya.

3. Deteksi Outlier

Deteksi outlier dilakukan untuk mengidentifikasi nilai-nilai yang berada jauh di luar pola umum data. Pada penelitian ini, deteksi outlier dilakukan melalui dua pendekatan. Pendekatan pertama menggunakan visualisasi boxplot pada seluruh variabel numerik setelah proses imputasi missing value selesai dilakukan. Melalui boxplot, keberadaan nilai ekstrem dapat diamati secara visual berdasarkan titik-titik yang berada di luar whisker. Pendekatan kedua menggunakan metode Interquartile Range (IQR). Metode ini menghitung rentang antar kuartil dengan rumus:

$$IQR = Q3 - Q1$$

Selanjutnya, batas bawah dan batas atas outlier ditentukan menggunakan persamaan:

$$BatasBawah = Q1 - 1,5 \times IQR$$

$$BatasAtas = Q3 + 1,5 \times IQR$$

Data yang berada di luar kedua batas tersebut dikategorikan sebagai outlier. Setelah itu dilakukan perhitungan jumlah outlier pada masing-masing variabel untuk mengetahui tingkat keberadaan nilai ekstrem dalam dataset. Pada penelitian ini, outlier tidak dihapus dari dataset. Keputusan tersebut diambil karena nilai-nilai yang terdeteksi masih dianggap mencerminkan kondisi nyata yang terjadi pada berbagai negara dalam dataset. Selain itu, jumlah data yang tersedia relatif terbatas sehingga penghapusan outlier berpotensi mengurangi informasi yang penting bagi model. Oleh karena itu, outlier tetap dipertahankan agar model dapat mempelajari variasi data secara lebih representatif dan menghasilkan prediksi yang lebih sesuai dengan kondisi sebenarnya.

3.5 Feature Importance dan Seleksi Fitur

Sebelum dilakukan analisis korelasi, kolom kategorik Status diubah menjadi data numerik menggunakan *Label Encoding* agar dapat diikutsertakan dalam perhitungan korelasi antarvariabel. Selanjutnya, dibuat matriks korelasi dan visualisasi *heatmap* untuk mengidentifikasi potensi multikolinearitas antar fitur, yaitu pasangan variabel dengan nilai

korelasi sangat tinggi (di atas 0,90). Fitur yang memiliki korelasi sangat tinggi dengan fitur lain dipertimbangkan untuk dihapus guna mengurangi redundansi informasi dalam dataset.

Setelah proses tersebut, dilakukan analisis tingkat kepentingan fitur menggunakan dua pendekatan, yaitu *feature importance* dari model XGBoost berdasarkan nilai *gain* dan metode SHAP (*SHapley Additive exPlanations*) menggunakan *shap.TreeExplainer*. Kemudian, hasil dari kedua pendekatan tersebut digunakan untuk mengidentifikasi fitur-fitur yang memiliki kontribusi besar terhadap prediksi angka harapan hidup. Apabila ditemukan fitur yang memiliki pengaruh sangat dominan sehingga berpotensi menutupi kontribusi fitur lain, dilakukan evaluasi lebih lanjut melalui penghapusan fitur tersebut dan pengulangan analisis *feature importance* serta SHAP. Langkah ini bertujuan untuk memperoleh pemahaman yang lebih komprehensif mengenai kontribusi masing-masing fitur terhadap hasil prediksi model.

3.6 Transformasi Data (Standardisasi)

Setelah proses seleksi fitur selesai dilakukan, data ditransformasikan menggunakan metode standardisasi dengan *StandardScaler* dari pustaka *sklearn.preprocessing*. Proses ini bertujuan untuk menyamakan skala antar fitur yang memiliki rentang nilai berbeda sehingga setiap fitur dapat memberikan kontribusi yang lebih seimbang dalam proses pemodelan.

Standardisasi dilakukan pada seluruh fitur numerik dalam dataset, termasuk kolom Status yang telah diubah menjadi data numerik melalui *Label Encoding* pada tahap sebelumnya. Adapun variabel target yaitu *Life Expectancy* tidak ikut ditransformasikan agar tetap mempertahankan nilai aslinya dan dapat diinterpretasikan dalam satuan tahun. Melalui proses standarisasi, seluruh fitur numerik memiliki skala yang lebih seragam sehingga perbedaan rentang nilai antar fitur tidak memengaruhi proses pelatihan model. Langkah ini juga mendukung proses pemodelan yang lebih konsisten serta memungkinkan perbandingan performa yang lebih adil antara model Regresi Linear dan model berbasis pohon keputusan yang digunakan dalam penelitian.

3.7 Penentuan Variabel X dan y

Setelah proses standardisasi selesai dilakukan, dataset hasil transformasi (*df_standardized*) digunakan untuk menentukan variabel target (y) dan variabel fitur (X). Variabel target ditetapkan sebagai kolom *Life Expectancy*, sedangkan variabel fitur diperoleh

dengan menghapus kolom *Life Expectancy* dan *Status* dari DataFrame tersebut. Dengan demikian, kolom 'Status' tidak diikutsertakan sebagai fitur pada tahap pemodelan akhir. Sehingga diperoleh sebanyak 14 fitur yang digunakan sebagai variabel independen dalam pembentukan model prediksi. Selanjutnya, dilakukan validasi menggunakan atribut `.shape` untuk memastikan bahwa dimensi variabel *y* dan *X* telah sesuai. Kemudian, sebagai pemeriksaan tambahan, ditampilkan beberapa baris pertama dari *y* dan *X* untuk memverifikasi bahwa kedua variabel telah terbentuk dengan benar dan siap digunakan pada tahap pembagian data serta pemodelan.

3.8 Pembagian Data (*Train-Test Split*)

Setelah variabel *y* dan *X* ditentukan, data dibagi menjadi data latih (*training set*) dan data uji (*testing set*) menggunakan fungsi `train_test_split` dari pustaka `sklearn.model_selection`. Proses pembagian dilakukan dengan parameter `test_size=0.2`, sehingga data dibagi dengan rasio 80:20 yang artinya sebanyak 80% data digunakan untuk melatih model, sedangkan 20% sisanya digunakan untuk menguji performa model pada data yang belum pernah digunakan selama proses pelatihan. Kemudian, parameter `random_state=42` ditetapkan agar proses pembagian data menghasilkan susunan yang konsisten dan dapat direproduksi kembali pada setiap eksekusi program. Lalu, sebagai langkah verifikasi, dilakukan pengecekan terhadap ukuran data latih dan data uji yang dihasilkan menggunakan atribut `.shape`. Tahap tersebut bertujuan untuk memastikan bahwa dimensi `X_train`, `X_test`, `y_train`, dan `y_test` telah sesuai dan konsisten, sehingga data siap digunakan pada tahap pemodelan dan evaluasi selanjutnya.

3.9 Pemodelan Machine Learning

Pada tahap ini, empat algoritma regresi dari *supervised machine learning* diterapkan untuk memprediksi variabel target kontinu. Keempat model dilatih menggunakan data latih (*training set*) yang telah melalui proses standarisasi (Z-score) untuk memastikan skala fitur tidak mendominasi proses pembelajaran, serta dievaluasi pada data uji (*test set*) yang terpisah

1. *Linear Regression*

Linear Regression merupakan algoritma dasar yang mengasumsikan hubungan linear antara variabel independen (fitur) dan variabel dependen (target), yang dimodelkan melalui

persamaan garis lurus $y=b_0+b_1X_1+...+b_nX_n$, di mana b adalah koefisien yang meminimalkan *sum of squared residuals*. Algoritma ini dipilih sebagai model *baseline* karena kesederhanaannya, interpretabilitasnya yang tinggi, serta kemampuannya untuk memberikan tolok ukur performa minimum. Jika model yang lebih kompleks tidak mampu mengungguli *Linear Regression* secara signifikan, maka kompleksitas tambahan tidak diperlukan. Proses pelatihan dilakukan dengan memanggil pustaka `sklearn.linear_model.LinearRegression` dan mengadaptasi (*fitting*) model pada data latih yang telah distandardisasi (`X_train_scaled`) terhadap target (`y_train`), tanpa menyertakan parameter regularisasi agar model mempelajari koefisien secara murni.

2. Decision Tree Regressor

Decision Tree Regressor adalah algoritma non-linear yang bekerja dengan mempartisi data menjadi sub-sub kelompok (*nodes*) berdasarkan aturan kondisi pada fitur tertentu (misalnya, "fitur $X > \text{nilai threshold}$ "). Proses ini berlangsung rekursif hingga mencapai *leaf* (daun) yang berisi nilai prediksi berupa rata-rata dari target pada kelompok tersebut. Algoritma ini dipilih sebagai pembanding untuk mengakomodasi pola data yang tidak linear dan interaksi antar fitur yang kompleks, yang tidak dapat ditangkap oleh *Linear Regression*. Parameter `random_state=42` diinisialisasi untuk mengendalikan proses pemecahan (*split*) yang melibatkan elemen acak (seperti pada pengacakan fitur terbaik), guna memastikan hasil yang konsisten dan *reproducible*. Proses pelatihan dilakukan dengan menginstansiasi objek `DecisionTreeRegressor` (`random_state=42`) dan memanggil metode `.fit()` pada `X_train_scaled` dan `y_train`.

3. Random Forest Regressor

Random Forest Regressor merupakan model berbasis *ensemble* yang menggabungkan banyak pohon keputusan melalui pendekatan *bagging* (Bootstrap Aggregating). Setiap pohon dilatih pada sampel data acak (*bootstrap sample*) dan hanya mempertimbangkan subset fitur acak pada setiap pemisahan (*split*), sehingga menghasilkan pohon-pohon yang *diverse* atau beragam. Prediksi akhir diperoleh dari rata-rata (*averaging*) seluruh prediksi dari setiap pohon. Penggunaan model ini bertujuan untuk mengurangi gejala *overfitting* yang umum terjadi pada pohon keputusan tunggal, sekaligus meningkatkan akurasi prediksi melalui pengurangan varians. Parameter `random_state=42` digunakan untuk memastikan

reproduktifitas proses pengacakan *bootstrap* dan pemilihan fitur. Pelatihan model dilakukan dengan menginisialisasi `RandomForestRegressor(random_state=42)` dan menyesuaikannya dengan data latih terstandarisasi.

4. *XGBoost Regressor*

XGBoost Regressor (Extreme Gradient Boosting) adalah model *ensemble* berbasis *boosting* yang membangun pohon-pohon keputusan secara berurutan (sekuesial), di mana setiap pohon baru dikonstruksi untuk mengoreksi kesalahan prediksi dari pohon-pohon sebelumnya dengan memanfaatkan gradien dari fungsi kerugian (*gradient descent*). Model ini dipilih karena kemampuannya yang sangat baik dalam menangani data tabular, ketahanan terhadap *outlier*, serta kinerja prediktif yang sering kali unggul dibandingkan algoritma lain. Pada tahap awal (*baseline* XGBoost sebelum tuning), parameter `random_state=42` ditetapkan untuk mengontrol pengacakan pada proses *subsampling* dan inisialisasi, guna menjaga stabilitas dan reproduktifitas hasil. Proses pelatihan model awal ini dilakukan dengan menginstansiasi `XGBRegressor(random_state=42)` dan melakukan *fitting* pada data latih yang telah distandarisasi.

3.10 Metrik Evaluasi

Untuk mengukur dan membandingkan kinerja keempat model secara kuantitatif dan objektif, digunakan empat metrik evaluasi regresi standar, yaitu *Mean Absolute Error* (MAE), *Mean Squared Error* (MSE), *Root Mean Squared Error* (RMSE), dan *R-squared* (R^2). Penjelasan singkat masing-masing metrik adalah sebagai berikut:

1. *Mean Absolute Error* (MAE): Mengukur rata-rata nilai absolut dari selisih antara nilai aktual dan nilai prediksi. MAE memiliki satuan yang sama dengan variabel target dan bersifat robust terhadap *outlier* karena tidak mengkuadratkan error.
2. *Mean Squared Error* (MSE): Mengukur rata-rata dari kuadrat selisih antara nilai aktual dan prediksi. Metrik ini memberikan bobot penalti yang lebih besar terhadap kesalahan yang besar (karena dikuadratkan), sehingga sangat sensitif terhadap *outlier*.
3. *Root Mean Squared Error* (RMSE): Merupakan akar kuadrat dari MSE. RMSE memiliki satuan yang sama dengan variabel target, sehingga lebih mudah

diinterpretasikan secara intuitif dibandingkan MSE, namun tetap mempertahankan sifat sensitivitas terhadap *outlier*.

4. *R-squared* (R^2) atau Koefisien Determinasi: Mengukur seberapa besar proporsi varians dari variabel target yang dapat dijelaskan oleh model. Nilai R^2 berkisar antara $-\infty$ hingga 1, di mana nilai 1 mengindikasikan model mampu menjelaskan seluruh variasi data dengan sempurna, sedangkan nilai 0 menunjukkan model tidak lebih baik daripada prediksi menggunakan rata-rata.

3.11 Hyperparameter Tuning

Setelah dilakukan evaluasi awal pada keempat model, *hyperparameter tuning* hanya diterapkan pada model *XGBoost Regressor*, dengan pertimbangan bahwa model ini menunjukkan performa awal (sebelum tuning) terbaik dibandingkan ketiga model lainnya. Tujuan tuning adalah untuk mengoptimalkan konfigurasi hyperparameter guna memaksimalkan kemampuan generalisasi model pada data uji.

Proses tuning dilakukan menggunakan metode *GridSearchCV* (*Grid Search Cross-Validation*) dengan jumlah *fold* sebanyak 5 ($cv=5$) dan metrik skor yang dioptimalkan adalah *neg_mean_squared_error* (nilai negatif dari MSE, karena pustaka *scikit-learn* memaksimalkan skor). Parameter yang diuji dalam grid pencarian meliputi:

1. *n_estimators*: [100, 200, 300] (jumlah pohon keputusan dalam ensemble).
2. *max_depth*: [3, 5, 7] (kedalaman maksimum setiap pohon).
3. *learning_rate*: [0.01, 0.1, 0.2] (langkah pengurangan bobot untuk mencegah overfitting).
4. *subsample*: [0.7, 0.8, 1.0] (proporsi sampel data latih yang digunakan untuk melatih setiap pohon).
5. *colsample_bytree*: [0.7, 0.8, 1.0] (proporsi fitur yang digunakan untuk melatih setiap pohon).

GridSearchCV akan melakukan pelatihan sebanyak kombinasi parameter ($3 \times 3 \times 3 \times 3 \times 3 = 243$ kombinasi) dikalikan 5 *fold*, sehingga total terdapat 1.215 proses pelatihan untuk menemukan kombinasi hyperparameter optimal. Setelah kombinasi terbaik ditemukan, model *XGBoost* yang telah dituning (*tuned model*) dievaluasi kembali pada data uji. Hasil evaluasi ini kemudian dibandingkan secara langsung dengan performa model *XGBoost* sebelum

tuning (*baseline model*) pada data uji yang sama, guna mengukur efektivitas proses tuning dalam meningkatkan akurasi prediksi.

3.12 Pemilihan Model Terbaik (Final)

Setelah proses *hyperparameter tuning* menggunakan GridSearchCV selesai dilakukan dan kombinasi parameter optimal untuk XGBoost Regressor berhasil ditemukan, tahap selanjutnya adalah menentukan model final (*final model*) yang akan digunakan sebagai dasar interpretasi dan penarikan kesimpulan penelitian. Pemilihan model akhir ini dilakukan dengan membandingkan secara langsung performa prediktif antara dua varian model XGBoost Regressor, yaitu model sebelum tuning (*baseline model* dengan parameter default dan `random_state=42`) dan model setelah tuning (*tuned model* dengan kombinasi hyperparameter terbaik hasil GridSearchCV). Kedua varian model tersebut dievaluasi pada *data uji* yang sama (`X_test_scaled` dan `y_test`) yang sepenuhnya terisolasi dan tidak pernah digunakan selama proses pelatihan maupun validasi silang, guna memastikan pengukuran kemampuan generalisasi yang objektif dan tidak bias.

Penetapan model final didasarkan pada perbandingan kinerja kuantitatif yang diukur melalui keempat metrik evaluasi regresi yang telah ditetapkan, yaitu MAE, MSE, RMSE, dan R^2 . Kriteria utama yang digunakan dalam pengambilan keputusan adalah nilai R-squared (R^2) yang lebih tinggi, karena metrik ini secara langsung merepresentasikan proporsi variansi variabel target yang mampu dijelaskan oleh model—semakin mendekati angka 1, semakin baik kemampuan model dalam menangkap pola data. Namun, dalam kondisi kedua model menunjukkan nilai R^2 yang relatif berdekatan, maka metrik Root Mean Squared Error (RMSE) yang lebih rendah akan dijadikan sebagai kriteria penentu tambahan. Hal ini dikarenakan RMSE memiliki satuan yang sama dengan variabel target sehingga lebih intuitif, serta memberikan penalti yang lebih besar terhadap kesalahan prediksi yang ekstrem, sehingga cocok untuk memilih model yang lebih konsisten. Model yang memenuhi kriteria optimal ini—yakni memiliki R^2 tertinggi atau RMSE terendah di antara keduanya—akan ditetapkan sebagai model terbaik (*best model*) untuk digunakan pada tahap analisis lanjutan, seperti interpretasi tingkat kepentingan fitur (*feature importance*) dan penarikan kesimpulan akhir penelitian.

Perlu ditekankan secara khusus bahwa perbandingan pada subbab ini secara eksplisit hanya melibatkan dua versi model XGBoost Regressor (sebelum dan sesudah tuning). Perbandingan komprehensif antara XGBoost dengan ketiga model lainnya—yakni *Linear Regression*, *Decision Tree Regressor*, dan *Random Forest Regressor*—telah dilakukan dan dibahas secara tuntas pada subbab evaluasi model sebelumnya (Sub-bab 3.10). Fokus pembatasan ruang lingkup perbandingan di tahap akhir ini semata-mata bertujuan untuk memvalidasi efektivitas dan dampak positif dari proses *hyperparameter tuning* terhadap peningkatan kapasitas generalisasi model XGBoost, serta untuk memastikan bahwa model yang dibawa ke tahap akhir merupakan versi yang paling optimal secara statistik dan siap diinterpretasikan.

BAB IV

HASIL DAN PEMBAHASAN


4.1 Hasil Penelaahan Data

1. Statistik Deskriptif

Dari hasil statistik deskriptif (*df.describe()*), beberapa temuan yang dapat dicatat antara lain:

- a. Life Expectancy (Harapan Hidup) memiliki rata-rata sebesar 69,22 tahun dengan nilai minimum 36,3 tahun dan maksimum 89 tahun, menunjukkan adanya perbedaan tingkat kesehatan yang cukup besar antar negara.
- b. Adult Mortality memiliki rata-rata sebesar 164,80 dengan standar deviasi 124,29, yang mengindikasikan variasi tingkat kematian orang dewasa yang cukup tinggi antar observasi.
- c. Alcohol Consumption memiliki rata-rata 4,60, sedangkan nilai maksimum mencapai 17,87, menunjukkan bahwa konsumsi alkohol berbeda secara signifikan di berbagai negara.
- d. Variabel imunisasi seperti Hepatitis B (rata-rata 80,94), Polio (82,55), dan Diphtheria (82,32) memiliki rata-rata yang relatif tinggi, menandakan bahwa sebagian besar negara dalam *dataset* telah memiliki cakupan imunisasi yang cukup baik.
- e. BMI memiliki rata-rata 38,32 dengan rentang nilai yang luas (1,0–87,3), menunjukkan variasi kondisi gizi penduduk antar negara.
- f. Variabel Measles memiliki rata-rata yang sangat tinggi (2.419,59) namun standar deviasi (11.467,27) yang jauh lebih besar dibanding rata-ratanya, menunjukkan bahwa masih terdapat beberapa negara dengan kasus campak yang sangat tinggi.
- g. Income Composition of Resources memiliki rata-rata 0,63, sedangkan Schooling memiliki rata-rata 11,99 tahun, yang mengindikasikan bahwa secara umum tingkat pembangunan sosial-ekonomi dan pendidikan berada pada kategori menengah hingga tinggi.
- h. Nilai standar deviasi yang relatif lebih kecil dibandingkan rata-rata pada sebagian besar variabel menunjukkan bahwa data cenderung tidak terlalu menyebar jauh dari nilai rata-ratanya, meskipun beberapa variabel seperti Adult Mortality, Alcohol, dan Measles masih menunjukkan variasi yang cukup besar.

2. Analisis Distribusi Variabel




Gambar 4.1 Histogram distribusi seluruh variabel numerik

Berdasarkan histogram distribusi variabel pada *dataset* Life Expectancy, interpretasinya dapat dituliskan sebagai berikut:

- a. Variabel Life Expectancy memiliki distribusi yang mendekati normal dengan sedikit *skewness* negatif (miring ke kiri). Sebagian besar nilai terkonsentrasi pada rentang menengah hingga tinggi (sekitar 65-80 tahun).
- b. Variabel Adult Mortality menunjukkan distribusi yang *right-skewed* (miring ke kanan), dengan sebagian besar nilai berada pada tingkat mortalitas rendah hingga sedang, namun terdapat beberapa nilai yang sangat tinggi.
- c. Variabel Alcohol memiliki distribusi *right-skewed*, ditandai dengan banyaknya negara yang memiliki konsumsi alkohol rendah dan hanya sedikit negara dengan konsumsi yang sangat tinggi.
- d. Variabel Percentage Expenditure menunjukkan distribusi yang sangat *right-skewed*. Sebagian besar observasi berada di dekat nol dengan beberapa nilai ekstrem yang sangat besar. Variabel ini berpotensi memerlukan transformasi logaritmik.
- e. Variabel Hepatitis B memiliki distribusi *left-skewed* (miring ke kiri). Mayoritas observasi memiliki tingkat imunisasi yang tinggi (mendekati 100%), sementara hanya sedikit negara dengan cakupan imunisasi rendah.
- f. Variabel Measles menunjukkan distribusi yang sangat *right-skewed*, dengan sebagian besar nilai berada pada tingkat kasus yang sangat rendah dan beberapa *outlier* dengan jumlah kasus yang sangat tinggi. Transformasi logaritmik dapat dipertimbangkan.
- g. Variabel BMI memiliki distribusi *bimodal* (dua puncak), yang mengindikasikan kemungkinan adanya dua kelompok populasi yang berbeda dalam data.
- h. Variabel Under-Five Deaths menunjukkan distribusi yang sangat *right-skewed*, dengan mayoritas negara memiliki jumlah kematian balita yang rendah dan beberapa negara memiliki nilai yang sangat tinggi.
- i. Variabel Polio memiliki distribusi *left-skewed*, karena sebagian besar negara memiliki cakupan imunisasi polio yang tinggi, mendekati nilai maksimum.
- j. Variabel Total Expenditure memiliki distribusi yang mendekati normal dengan sedikit *skewness* positif, menunjukkan penyebaran data yang relatif seimbang meskipun masih terdapat beberapa nilai tinggi.

- k. Variabel Diphtheria menunjukkan distribusi *left-skewed*, dengan mayoritas observasi berada pada tingkat imunisasi yang tinggi.
- l. Variabel Population memiliki distribusi yang sangat *right-skewed*, karena sebagian besar negara memiliki jumlah penduduk relatif kecil, sementara beberapa negara memiliki populasi yang sangat besar. Variabel ini sangat disarankan untuk ditransformasikan menggunakan logaritma.
- m. Variabel Thinness 5-9 Years memiliki distribusi *right-skewed*, menunjukkan bahwa sebagian besar negara memiliki tingkat kekurangan anak yang rendah hingga sedang.
- n. Variabel Income Composition of Resources memiliki distribusi *left-skewed* ringan, dengan sebagian besar nilai berada pada tingkat menengah hingga tinggi.
- o. Variabel Schooling memiliki distribusi yang mendekati normal, dengan konsentrasi observasi pada tingkat pendidikan menengah hingga tinggi.




Gambar 4.2 Boxplot semua variabel numerik

Berdasarkan *boxplot* variabel numerik pada *dataset* Life Expectancy, interpretasinya dapat dituliskan sebagai berikut:

- a. Life Expectancy memiliki median sekitar 72 tahun dengan penyebaran data yang cukup lebar. Terdapat beberapa *outlier* bawah, yang menunjukkan adanya negara dengan harapan hidup jauh lebih rendah dibanding mayoritas negara.
- b. Adult Mortality menunjukkan banyak *outlier* atas, mengindikasikan adanya beberapa negara dengan tingkat kematian dewasa yang jauh lebih tinggi dibanding sebagian besar negara lainnya.
- c. Alcohol memiliki variasi yang cukup besar antar negara. Terdapat beberapa *outlier* atas yang menunjukkan negara dengan tingkat konsumsi alkohol yang sangat tinggi dibanding mayoritas observasi.
- d. Percentage Expenditure menunjukkan jumlah *outlier* yang sangat banyak pada nilai tinggi. Sebagian besar data terkonsentrasi pada nilai rendah, sementara beberapa negara memiliki pengeluaran kesehatan yang jauh lebih besar.
- e. Hepatitis B memiliki median yang tinggi dan sebagian besar data berada pada tingkat imunisasi yang baik. Namun terdapat banyak *outlier* bawah, menunjukkan negara dengan cakupan imunisasi Hepatitis B yang jauh lebih rendah.
- f. Measles menunjukkan box yang sangat sempit di dekat nol dengan banyak *outlier* atas. Ini mengindikasikan bahwa sebagian besar negara memiliki kasus campak yang rendah, tetapi terdapat beberapa negara dengan jumlah kasus yang sangat tinggi.
- g. BMI memiliki penyebaran data yang cukup merata dan hampir tidak terdapat *outlier* ekstrem. Variabel ini relatif lebih stabil dibanding variabel lainnya.
- h. Under-Five Deaths memiliki jumlah *outlier* atas yang sangat banyak. Sebagian besar negara memiliki angka kematian balita yang rendah, namun terdapat beberapa negara dengan tingkat kematian balita yang jauh lebih tinggi.
- i. Polio memiliki median yang tinggi dengan sebagian besar data terkonsentrasi pada cakupan imunisasi yang baik. Terdapat sejumlah *outlier* bawah yang menunjukkan negara dengan cakupan imunisasi polio yang relatif rendah.
- j. Total Expenditure menunjukkan distribusi yang relatif lebih seimbang dibanding Percentage Expenditure, tetapi masih terdapat beberapa *outlier* atas.

- k. Diphtheria memiliki pola yang mirip dengan Polio dan Hepatitis B. Median berada pada tingkat yang tinggi, sedangkan beberapa *outlier* bawah menunjukkan negara dengan cakupan imunisasi difteri yang rendah.
- l. Population memiliki distribusi yang sangat terkonsentrasi pada nilai rendah dengan sejumlah *outlier* atas yang ekstrem, mencerminkan adanya beberapa negara berpenduduk sangat besar.
- m. Thinness 5–9 Years memiliki banyak *outlier* atas, menunjukkan bahwa sebagian besar negara memiliki tingkat kekurangan anak yang rendah, namun terdapat beberapa negara dengan tingkat kekurangan yang jauh lebih tinggi.
- n. Income Composition of Resources memiliki distribusi yang relatif simetris dengan sedikit *outlier*.
- o. Schooling menunjukkan distribusi yang cukup mendekati simetris dengan beberapa *outlier* bawah dan atas.

3. Analisis Korelasi



Gambar 4.3 Heatmap (matriks) korelasi seluruh variabel numerik

Berdasarkan *heatmap* korelasi variabel numerik pada *dataset* Life Expectancy, interpretasinya dapat dituliskan sebagai berikut:

Variabel dengan Korelasi Positif Tertinggi terhadap Life Expectancy:

- a. Schooling ($r = 0,75$) memiliki korelasi positif terkuat dengan Life Expectancy. Semakin tinggi rata-rata lama sekolah, semakin tinggi angka harapan hidup.
- b. Income Composition of Resources ($r = 0,72$) menunjukkan hubungan positif yang kuat. Negara dengan kualitas pembangunan sumber daya yang lebih baik cenderung memiliki harapan hidup yang lebih tinggi.
- c. BMI ($r = 0,57$) menunjukkan hubungan positif sedang hingga kuat. Status gizi yang lebih baik berkaitan dengan peningkatan harapan hidup.
- d. Diphtheria ($r = 0,48$) menunjukkan bahwa cakupan imunisasi yang tinggi berasosiasi dengan harapan hidup yang lebih tinggi.
- e. GDP ($r = 0,46$) mengindikasikan bahwa kondisi ekonomi yang lebih baik umumnya diikuti oleh peningkatan harapan hidup.
- f. Polio ($r = 0,47$) menunjukkan hubungan positif antara cakupan imunisasi polio dan angka harapan hidup.

Variabel dengan Korelasi Negatif Tertinggi terhadap Life Expectancy:

- a. Adult Mortality ($r = -0,70$) memiliki korelasi negatif terkuat. Semakin tinggi tingkat kematian dewasa, semakin rendah angka harapan hidup.
- b. HIV/AIDS ($r = -0,56$) menunjukkan hubungan negatif yang kuat terhadap Life Expectancy.
- c. Thinness 1–19 Years ($r = -0,48$) menunjukkan bahwa tingginya tingkat kekurangan pada anak dan remaja berkaitan dengan rendahnya harapan hidup.
- d. Thinness 5–9 Years ($r = -0,47$) juga memiliki hubungan negatif yang cukup kuat dengan harapan hidup.
- e. Under-Five Deaths ($r = -0,22$) menunjukkan bahwa meningkatnya kematian balita cenderung menurunkan harapan hidup.
- f. Infant Deaths ($r = -0,20$) memiliki hubungan negatif, meskipun relatif lebih lemah dibanding variabel lainnya.

Pasangan Variabel dengan Multikolinearitas Tinggi:

- a. Infant Deaths dan Under-Five Deaths ($r = 1,00$) memiliki korelasi hampir sempurna, sehingga keduanya memberikan informasi yang sangat mirip.
- b. Thinness 1-19 Years dan Thinness 5-9 Years ($r = 0,94$) menunjukkan hubungan yang sangat kuat dan berpotensi menyebabkan multikolinearitas pada model.
- c. Schooling dan Income Composition of Resources ($r = 0,80$) menunjukkan bahwa negara dengan tingkat pendidikan tinggi cenderung memiliki kualitas pembangunan ekonomi yang lebih baik.
- d. GDP dan Percentage Expenditure ($r = 0,90$) mengindikasikan hubungan yang sangat kuat antara kondisi ekonomi dan pengeluaran kesehatan per kapita.

Kesimpulan analisis korelasi:

- a. Schooling dan Income Composition of Resources merupakan variabel yang paling berpengaruh positif terhadap Life Expectancy.
- b. Adult Mortality dan HIV/AIDS merupakan variabel yang paling berpengaruh negatif terhadap Life Expectancy.
- c. Terdapat multikolinearitas sangat tinggi pada pasangan Infant Deaths–Under-Five Deaths dan Thinness 1-19 Years–Thinness 5-9 Years, sehingga salah satu variabel pada masing-masing pasangan dapat dipertimbangkan untuk dihapus saat membangun model prediksi.
- d. Secara umum, faktor pendidikan, ekonomi, status gizi, dan cakupan imunisasi berhubungan positif dengan harapan hidup, sedangkan mortalitas, HIV/AIDS, dan masalah gizi berhubungan negatif dengan harapan hidup.

4. Analisis Missing Value dan Outlier

Pengecekan missing value menghasilkan temuan sebagai berikut:

- a. Total missing value ditemukan pada 14 variabel dari 22 variabel yang ada dalam *dataset*.
- b. Variabel dengan missing value terbanyak adalah Population dengan 652 data hilang atau sekitar 22,19% dari total 2.938 observasi.
- c. Variabel lain dengan missing value yang cukup tinggi adalah Hepatitis B sebanyak 553 data (18,82%) dan GDP sebanyak 448 data (15,25%).
- d. Variabel Alcohol (6,60%), Total Expenditure (7,69%), Income Composition of Resources (5,68%), dan Schooling (5,55%) memiliki tingkat missing value sedang.

- e. Variabel seperti Life Expectancy (0,34%), Adult Mortality (0,34%), Polio (0,65%), Diphtheria (0,65%), BMI (1,16%), Thinness 1–19 Years (1,16%), dan Thinness 5–9 Years (1,16%) memiliki proporsi missing value yang relatif kecil.
- f. Sebanyak 8 variabel tidak memiliki missing value sama sekali, yaitu Country, Year, Status, Infant Deaths, Percentage Expenditure, Measles, Under-Five Deaths, dan HIV/AIDS.

Pengecekan *outlier* dengan metode IQR menghasilkan temuan sebagai berikut:

- a. Outlier terdeteksi pada hampir seluruh variabel numerik menggunakan metode Interquartile Range (IQR), yang mengidentifikasi nilai di luar rentang normal data.
- b. Variabel dengan jumlah *outlier* terbanyak adalah Measles (542) dan HIV/AIDS (542). Hal ini menunjukkan adanya beberapa negara dengan jumlah kasus campak dan prevalensi HIV/AIDS yang sangat tinggi dibandingkan mayoritas negara lainnya.
- c. Variabel Status memiliki 512 *outlier*, namun karena merupakan variabel kategorik yang dikonversi ke numerik, hasil deteksi *outlier* pada variabel ini kurang relevan untuk dianalisis.
- d. Variabel Under-Five Deaths (394), Percentage Expenditure (389), Hepatitis B (322), dan Infant Deaths (315) menunjukkan banyak *outlier*, mengindikasikan adanya perbedaan kondisi kesehatan dan pengeluaran kesehatan yang cukup besar antar negara.
- e. Variabel GDP (445) dan Population (452) memiliki jumlah *outlier* yang tinggi, mencerminkan adanya beberapa negara dengan tingkat ekonomi dan jumlah penduduk yang jauh lebih besar dibandingkan negara lainnya.
- f. Variabel Polio (279) dan Diphtheria (298) juga memiliki banyak *outlier*, menunjukkan adanya negara dengan cakupan imunisasi yang jauh lebih rendah dibanding mayoritas negara.
- g. Variabel Income Composition of Resources (130) dan Schooling (77) memiliki sejumlah *outlier* yang menunjukkan adanya perbedaan tingkat pembangunan sumber daya manusia dan pendidikan antar negara.
- h. Variabel Adult Mortality (86), Thinness 1-19 Years (100), dan Thinness 5-9 Years (99) memiliki *outlier* dalam jumlah sedang.

- i. Variabel Alcohol (3) hanya memiliki sedikit *outlier* sehingga distribusinya relatif stabil dan tidak terlalu dipengaruhi oleh nilai ekstrem.
- j. Variabel BMI (0) tidak memiliki *outlier*, menunjukkan bahwa distribusi data BMI relatif seragam dan stabil dibandingkan variabel lainnya.
- k. Secara keseluruhan, banyaknya *outlier* pada variabel Measles, HIV/AIDS, GDP, Population, Percentage Expenditure, Infant Deaths, dan Under-Five Deaths mengindikasikan adanya ketimpangan yang besar antar negara dalam aspek kesehatan, ekonomi, dan demografi.

4.2 Hasil Validasi

Hasil pemeriksaan kualitas data menunjukkan: tidak ditemukan baris duplikat (0 duplikat), tidak ditemukan nilai negatif pada kolom numerik mana pun, dan dataset memiliki dimensi (2.938, 20) setelah penghapusan kolom identitas.

Tabel 4.1 Jumlah *missing value* per kolom

Kolom	Jumlah Missing Value
Population	652
Hepatitis B	553
GDP	448
Total expenditure	226
Alcohol	194
Income composition of resources	167
Schooling	163
BMI, thinness 1-19 years, thinness 5-9 years	34 (masing-masing)
Polio, Diphtheria	19 (masing-masing)
Life expectancy, Adult Mortality	10 (masing-masing)

4.3 Pembersihan Data (Data Cleaning)

Setelah proses validasi data pada tahap sebelumnya mengidentifikasi adanya *missing value* pada beberapa kolom numerik, tahap pembersihan data (*data cleaning*) dilakukan untuk memastikan dataset siap digunakan pada proses pemodelan selanjutnya. Tahap ini mencakup tiga proses utama, yaitu penanganan *missing value*, pengecekan ulang data duplikat, dan deteksi outlier pada seluruh kolom numerik.

1. Penanganan *Missing Value*

Berdasarkan hasil pengecekan *missing value* menggunakan fungsi `df.isna().sum()`, ditemukan bahwa terdapat empat belas kolom numerik yang memiliki nilai kosong, yaitu Life expectancy, Adult Mortality, Alcohol, Hepatitis B, BMI, Polio, Total expenditure, Diphtheria, GDP, Population, thinness 1-19 years, thinness 5-9 years, Income composition of resources, dan Schooling. Jumlah missing value pada setiap kolom tersebut bervariasi, mulai dari yang paling sedikit yaitu 10 data pada kolom Life expectancy dan Adult Mortality, hingga yang paling banyak yaitu 652 data pada kolom Population.

Untuk menangani *missing value* tersebut, kelompok menggunakan metode imputasi median, yaitu mengisi setiap nilai yang kosong pada suatu kolom dengan nilai tengah (median) dari kolom yang bersangkutan. Proses ini dilakukan menggunakan fungsi `.median()` yang dikombinasikan dengan `.fillna()` pada setiap kolom numerik yang memiliki nilai kosong, sehingga seluruh missing value pada keempat belas kolom tersebut berhasil tergantikan.

Pemilihan median sebagai metode imputasi didasarkan pada pertimbangan bahwa median bersifat lebih tahan (*robust*) terhadap pengaruh nilai outlier dibandingkan dengan mean (rata-rata). Hal ini didukung oleh hasil visualisasi histogram pada tahap penelaahan data sebelumnya, yang menunjukkan bahwa sebagian besar kolom numerik pada dataset ini seperti GDP, Population, Hepatitis B, Polio, dan Diphtheria memiliki distribusi yang miring (*skewed*), baik miring ke kanan (*right-skewed*) maupun miring ke kiri (*left-skewed*). Pada distribusi yang miring, nilai mean akan mudah tertarik ke arah nilai-nilai ekstrem sehingga tidak lagi mewakili kondisi data secara representatif, sedangkan nilai median tetap berada di posisi tengah data dan tidak terpengaruh oleh nilai ekstrem tersebut. Dengan demikian, penggunaan median dipandang lebih tepat untuk menjaga keaslian distribusi data setelah proses imputasi dilakukan.

2. Penanganan Duplikasi

Setelah seluruh *missing value* ditangani melalui proses imputasi median, kelompok melakukan pengecekan ulang terhadap kemungkinan adanya data duplikat pada dataset. Pengecekan ini perlu dilakukan kembali karena proses imputasi dapat mengubah nilai-nilai


pada baris data, sehingga ada kemungkinan baris yang sebelumnya berbeda menjadi identik satu sama lain, atau sebaliknya. Pengecekan dilakukan menggunakan fungsi `uplicated()` yang diterapkan pada seluruh `DataFrame`, kemudian jumlah barisnya dihitung menggunakan `len()`. Hasil dari pengecekan ini menunjukkan keluaran jumlah data duplikat = 0, yang berarti tidak ditemukan satu pun baris data yang terduplikasi pada dataset setelah proses pembersihan *missing value* dilakukan. Karena hasil pengecekan menunjukkan jumlah duplikat sama dengan nol, maka tidak diperlukan langkah penghapusan baris (*drop duplicates*) pada tahap ini dan seluruh baris data tetap dipertahankan untuk dianalisis pada tahap selanjutnya.

3. Deteksi Outlier

Deteksi outlier dilakukan dengan dua cara, yaitu visualisasi boxplot dan perhitungan jumlah outlier menggunakan metode Interquartile Range (IQR). Kedua cara ini dilakukan setelah seluruh missing value pada kolom numerik diimputasi dengan nilai median, sehingga hasil deteksi mencerminkan kondisi data yang telah bersih dari nilai kosong.

a. Visualisasi Boxplot

Visualisasi boxplot dibuat untuk seluruh kolom numerik guna melihat persebaran data serta keberadaan titik-titik ekstrem secara visual. Hasil boxplot yang disajikan pada Gambar 4.1 menunjukkan bahwa meskipun *missing value* telah diimputasi, sebagian besar kolom numerik masih memperlihatkan keberadaan outlier dalam jumlah yang cukup banyak. Kolom-kolom seperti infant deaths, Measles, under-five deaths, HIV/AIDS, GDP, dan Population terlihat memiliki titik-titik outlier yang signifikan dan tersebar cukup jauh dari rentang interquartile-nya, sejalan dengan pola yang sebelumnya juga teramati pada boxplot sebelum proses imputasi dilakukan.



Gambar 4.4 Boxplot seluruh kolom numerik setelah missing value diimputasi

b. Perhitungan Outlier dengan Metode IQR

Selain secara visual, jumlah outlier pada setiap kolom numerik juga dihitung secara kuantitatif menggunakan metode Interquartile Range (IQR). Pada metode ini, suatu nilai dikategorikan sebagai outlier apabila berada di luar batas bawah dan batas atas yang dihitung dengan rumus $Q1 - 1,5 \times IQR$ untuk batas bawah, dan $Q3 + 1,5 \times IQR$ untuk batas atas, di mana $Q1$ merupakan kuartil pertama, $Q3$ merupakan kuartil ketiga, dan IQR adalah selisih antara $Q3$ dan $Q1$. Hasil perhitungan jumlah outlier untuk setiap kolom numerik disajikan pada Tabel 4.1.

Tabel 4.2 *Output* perhitungan outlier

Kolom Numerik	Jumlah Outlier
<i>Status</i>	512
<i>Life expectancy</i>	17
<i>Adult Mortality</i>	86
<i>infant deaths</i>	315
<i>Alcohol</i>	3
<i>percentage expenditure</i>	389
<i>Hepatitis B</i>	322
<i>Measles</i>	542
<i>BMI</i>	0
<i>under-five deaths</i>	394
<i>Polio</i>	279
<i>Total expenditure</i>	51
<i>Diphtheria</i>	298
<i>HIV/AIDS</i>	542
<i>GDP</i>	445
<i>Population</i>	452
<i>thinness 1-19 years</i>	100
<i>thinness 5-9 years</i>	99
<i>Income composition of resources</i>	130
<i>Schooling</i>	77

Tabel 4.1 Jumlah outlier per kolom numerik berdasarkan metode IQR

Berdasarkan Tabel 4.1, terlihat bahwa hampir seluruh kolom numerik memiliki outlier, dengan beberapa kolom menunjukkan jumlah outlier yang sangat tinggi, seperti Measles dan HIV/AIDS yang masing-masing memiliki 542 outlier, under-five deaths dengan 394 outlier, serta percentage expenditure dengan 389 outlier. Kondisi ini sejalan dengan hasil visualisasi histogram pada tahap sebelumnya yang menunjukkan distribusi miring (skewed) pada kolom-kolom tersebut, serta sejalan pula dengan boxplot pada Gambar 4.1 yang memperlihatkan banyak titik ekstrem. Satu-satunya kolom yang tidak memiliki outlier berdasarkan metode IQR ini adalah kolom BMI.

Pada tahap ini, outlier hanya dideteksi dan dihitung jumlahnya, tanpa dilakukan penghapusan baris data (removal) sama sekali. Kelompok memutuskan untuk membiarkan outlier apa adanya pada dataset yang akan digunakan untuk pemodelan, dengan beberapa pertimbangan berikut:

1. Jumlah outlier yang ditemukan sangat banyak dan tersebar pada hampir seluruh kolom numerik, sehingga jika seluruh baris yang mengandung outlier dihapus, jumlah data yang tersisa untuk proses pemodelan dapat berkurang secara drastis dan berpotensi mengurangi representativitas dataset.
2. Sebagian besar outlier yang terdeteksi diduga merupakan variasi alami antarnegara, bukan murni kesalahan pencatatan data (data entry error). Sebagai contoh, nilai outlier yang tinggi pada kolom GDP atau Population kemungkinan besar mencerminkan kondisi nyata pada negara-negara dengan ekonomi atau jumlah penduduk yang sangat besar, sehingga nilai tersebut tetap valid secara substansi dan relevan untuk dianalisis.
3. Beberapa model regresi yang akan digunakan pada tahap pemodelan selanjutnya, seperti Decision Tree, Random Forest, dan XGBoost, bersifat lebih tahan (robust) terhadap pengaruh outlier dibandingkan model linear sederhana, sehingga keberadaan outlier tidak serta-merta akan merusak performa model secara signifikan.
4. Penghapusan outlier secara langsung tanpa analisis domain yang mendalam berisiko menghilangkan informasi penting yang justru dapat menjadi sinyal yang bermakna dalam memprediksi variabel target Life expectancy, misalnya pada negara-negara dengan kondisi kesehatan atau ekonomi yang ekstrem.


Dengan pertimbangan-pertimbangan tersebut, kelompok memutuskan untuk tidak menghapus baris yang mengandung outlier pada tahap pembersihan data ini. Penanganan lebih lanjut terhadap kolom-kolom yang berpotensi mengganggu kualitas model, jika diperlukan, akan dipertimbangkan kembali pada tahap konstruksi data maupun pemodelan berikutnya.

4.4 Hasil *Feature Importance* dan Seleksi Fitur

1. Label Encoding Kolom Status

Kolom Status yang semula bertipe kategorik dengan nilai *Developing* dan *Developed* diubah menjadi numerik menggunakan Label Encoding, menghasilkan nilai 0 untuk *Developed* dan 1 untuk *Developing*. Dari total 2.938 baris data, terdapat 512 entri negara maju dan 2.426 entri negara berkembang.


2. Analisis Korelasi dan Penghapusan Fitur




Gambar 4.5 Heatmap korelasi seluruh variabel numerik

Setelah seluruh variabel berbentuk numerik, dilakukan analisis korelasi menggunakan heatmap untuk mendeteksi multikolinearitas. Berdasarkan heatmap korelasi, ditemukan beberapa pasangan fitur dengan korelasi sangat tinggi. Korelasi antara thinness 1-19 years dan thinness 5-9, under-five deaths dengan infant deaths, serta percentage expenditure dengan GDP. Ketiga pasangan fitur ini mengindikasikan adanya redundansi informasi yang berpotensi menyebabkan multikolinearitas. Oleh karena itu, diputuskan untuk menghapus tiga fitur yaitu percentage expenditure karena memiliki korelasi tinggi dengan GDP, thinness 5-9 years karena memiliki korelasi sangat tinggi dengan thinness 1-19 years, dan infant deaths karena memiliki korelasi tinggi dengan under-five deaths.

3. Analisis *Feature Importance* dan SHAP Tahap Awal (Dengan HIV/AIDS)



Gambar 4.6 *Feature Importance* model awal




Gambar 4.7 Plot SHAP model awal


Setelah penghapusan fitur redundan, dilakukan analisis *feature importance* menggunakan XGBoost Regressor untuk mengidentifikasi fitur-fitur yang paling berpengaruh terhadap prediksi Angka Harapan Hidup. Hasil analisis menunjukkan bahwa HIV/AIDS muncul sebagai fitur paling dominan yang berarti fitur ini mendominasi prediksi secara berlebihan. Fitur Income composition of resources berada di posisi kedua diikuti Adult Mortality dan under-five deaths sebesar. Dominasi HIV/AIDS ini juga terkonfirmasi dari analisis SHAP, di mana HIV/AIDS memiliki rentang dampak SHAP terluas. Nilai HIV/AIDS yang tinggi (warna merah) cenderung memiliki nilai SHAP negatif yang sangat besar, yang berarti tingginya tingkat kematian akibat HIV/AIDS sangat menurunkan prediksi Angka Harapan Hidup, terutama di negara-negara dengan prevalensi HIV/AIDS tinggi seperti di Afrika Sub-Sahara. Dominasi HIV/AIDS yang mencapai lebih dari 75% berpotensi menutupi (masking) pengaruh fitur-fitur lain yang juga penting secara domain dan ilmiah, seperti faktor ekonomi, pendidikan, dan kesehatan dasar lainnya. Oleh karena itu, diputuskan

untuk menghapus fitur HIV/AIDS agar model dapat memberikan gambaran yang lebih seimbang tentang faktor-faktor penentu Angka Harapan Hidup secara universal.

4. Analisis *Feature Importance* dan SHAP Tahap Kedua (Tanpa HIV/AIDS)



Gambar 4.8 *Feature Importance* setelah drop HIV/AIDS



Gambar 4.9 Plot SHAP setelah drop HIV/AIDS

Setelah HIV/AIDS dihapus, dilakukan kembali analisis feature importance dan SHAP untuk melihat perubahan dalam kontribusi fitur-fitur lainnya. Hasil analisis menunjukkan perubahan signifikan dalam peringkat dan kontribusi fitur-fitur yang tersisa. Income composition of resources menjadi fitur paling dominan dengan kontribusi sebesar 64.66%, mencerminkan bahwa indeks komposisi pendapatan dan sumber daya suatu negara merupakan faktor terpenting dalam menentukan Angka Harapan Hidup. Adult Mortality menempati posisi kedua dengan kontribusi 21.34%, menunjukkan bahwa tingkat kematian dewasa merupakan faktor kesehatan yang sangat signifikan. under-five deaths naik ke posisi ketiga dengan kontribusi 4.31%, diikuti oleh Diphtheria dan thinness 1-19 years masing-masing sebesar 1.85%, serta Schooling sebesar 1.34%. Analisis SHAP setelah penghapusan HIV/AIDS juga menunjukkan perubahan yang signifikan. Adult Mortality kini menjadi fitur dengan rentang dampak SHAP terluas, di mana nilai Adult Mortality yang tinggi (warna merah) cenderung memiliki nilai SHAP negatif yang besar yang berarti menurunkan prediksi Angka Harapan Hidup, sedangkan nilai rendah (warna biru) memiliki nilai SHAP positif yang meningkatkan prediksi. Income composition of resources menunjukkan dampak positif yang kuat, di mana nilai indeks yang tinggi mendorong prediksi Angka Harapan Hidup lebih tinggi. under-five deaths juga menunjukkan dampak negatif yang kuat, di mana tingkat kematian balita yang tinggi sangat mengurangi prediksi Angka Harapan Hidup. Schooling menunjukkan dampak positif yang jelas, di mana rata-rata tahun bersekolah yang lebih tinggi meningkatkan prediksi Angka Harapan Hidup, mencerminkan peran pendidikan dalam meningkatkan kesadaran kesehatan dan kemampuan ekonomi.

5. Kesimpulan Seleksi Fitur

Berdasarkan seluruh proses *feature engineering* dan seleksi fitur, fitur-fitur yang digunakan dalam pemodelan akhir adalah 14 fitur yaitu Adult Mortality, Alcohol, Hepatitis B, Measles, BMI, under-five deaths, Polio, Total expenditure, Diphtheria, GDP, Population, thinness 1-19 years, Income composition of resources, dan Schooling. Sedangkan fitur-fitur yang dihapus meliputi Country dan Year karena tidak relevan sebagai fitur prediktif, percentage expenditure, thinness 5-9 years, dan infant deaths karena multikolinearitas, serta HIV/AIDS karena dominasi yang berlebihan dalam prediksi. Dengan susunan fitur akhir ini, data siap untuk memasuki tahap selanjutnya.

4.5 Transformasi Data (Standardisasi)

Berdasarkan hasil standardisasi, seluruh variabel numerik telah ditransformasikan ke dalam skala yang sama menggunakan metode standardisasi. Proses ini menghasilkan data dengan nilai rata-rata mendekati 0 dan standar deviasi mendekati 1 pada setiap variabel. Dengan demikian, perbedaan rentang nilai antarvariabel dapat diminimalkan sehingga tidak ada variabel yang memiliki pengaruh lebih besar hanya karena memiliki skala yang lebih tinggi.

Nilai hasil standardisasi menunjukkan posisi suatu data terhadap rata-rata variabelnya. Nilai positif menunjukkan bahwa data berada di atas rata-rata, sedangkan nilai negatif menunjukkan bahwa data berada di bawah rata-rata. Semakin besar nilai absolut yang dihasilkan, semakin jauh posisi data tersebut dari rata-rata.

Standardisasi dilakukan untuk meningkatkan kualitas proses pemodelan, terutama pada algoritma machine learning yang sensitif terhadap perbedaan skala data. Dengan skala yang seragam, proses pelatihan model menjadi lebih stabil dan hasil prediksi yang diperoleh dapat lebih optimal.

4.6 Penentuan Variabel X dan y

Setelah proses prapemrosesan data selesai dilakukan, tahap berikutnya adalah menentukan variabel independen (X) dan variabel dependen (y) yang akan digunakan dalam proses pemodelan. Pada penelitian ini, variabel dependen (y) adalah Life expectancy karena merupakan variabel yang menjadi target prediksi. Sementara itu, variabel independen (X) terdiri atas 14 fitur yang diduga memengaruhi angka harapan hidup, yaitu Adult Mortality, Alcohol, Hepatitis B, Measles, BMI, under-five deaths, Polio, Total expenditure, Diphtheria, GDP, Population, thinness 1–19 years, Income composition of resources, dan Schooling. Variabel-variabel tersebut digunakan sebagai prediktor untuk mempelajari hubungan dengan variabel target.

Hasil pemisahan data menunjukkan bahwa variabel X memiliki ukuran (2938, 14), yang berarti terdapat 2.938 observasi dengan 14 fitur prediktor. Sementara itu, variabel y memiliki ukuran (2938,) yang menunjukkan terdapat 2.938 nilai target yang sesuai dengan setiap observasi pada variabel X. Contoh lima baris pertama variabel X menunjukkan nilai fitur yang telah melalui proses standardisasi, sehingga seluruh variabel berada pada skala

yang seragam. Adapun lima baris pertama variabel y menunjukkan nilai asli dari Life expectancy yang akan diprediksi oleh model regresi. Dengan pemisahan ini, data telah siap digunakan pada tahap pembagian data latih dan data uji serta proses pemodelan selanjutnya.

4.7 Pembagian Data (*Train-Test Split*)

Setelah variabel X dan y ditentukan, data dibagi menjadi data latih (*training set*) dan data uji (*testing set*) menggunakan fungsi `train_test_split` dari pustaka `sklearn.model_selection`. Proses pembagian dilakukan dengan rasio 80:20 menggunakan parameter `test_size=0.2`, sehingga 80% data digunakan untuk melatih model dan 20% sisanya digunakan untuk menguji performa model. Selain itu, parameter `random_state=42` digunakan untuk memastikan bahwa hasil pembagian data dapat direproduksi secara konsisten pada setiap eksekusi program.

Berdasarkan hasil pembagian data, diperoleh data latih dengan dimensi (2350, 14) dan data uji dengan dimensi (588, 14). Hal ini menunjukkan bahwa masing-masing dataset terdiri atas 14 fitur, dengan 2350 observasi pada data latih dan 588 observasi pada data uji. Data latih digunakan dalam proses pelatihan model, sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi pada data yang belum pernah digunakan selama proses pelatihan. Pembagian data dengan proporsi 80:20 memberikan jumlah data latih yang cukup untuk mempelajari pola hubungan antarvariabel, sekaligus menyediakan data uji yang representatif untuk mengevaluasi kemampuan generalisasi model. Dengan demikian, hasil evaluasi yang diperoleh diharapkan dapat memberikan gambaran yang lebih objektif mengenai performa model pada data baru.

4.8 Pemodelan

Setelah melalui tahap *feature engineering* dan pembagian data (80% training, 20% testing), empat model regresi dilatih dan dievaluasi menggunakan data testing. Empat algoritma regresi yang dipilih untuk dibandingkan, yaitu:

1. Linear Regression sebagai model *baseline*.
2. Decision Tree Regressor sebagai representasi model berbasis pohon keputusan tunggal.
3. Random Forest Regressor sebagai representasi model *ensemble* berbasis *bagging*.
4. XGBoost Regressor sebagai representasi model *ensemble* berbasis *boosting*.

Keempat model dilatih menggunakan data latih dan dievaluasi menggunakan data uji dengan metrik MAE (*Mean Absolute Error*), RMSE (*Root Mean Squared Error*), dan R^2 (*R-squared*). Performa awal dari keempat model ditampilkan pada Tabel berikut.

Tabel 4.3 Ringkasan evaluasi model

Model	MAE	MSE	RMSE	R^2
Linear Regression	3.1866	20.2689	4.5021	0.7661
Decision Tree Regressor	1.6784	9.2347	3.0389	0.8934
Random Forest Regressor	1.1443	3.2791	1.8108	0.9622
XGBoost Regressor	1.1959	3.0155	1.7365	0.9652

Berdasarkan Tabel 4.3 dapat dianalisis performa masing-masing model sebagai berikut:

1. *Linear Regression*

Model ini menunjukkan performa yang paling rendah di antara keempat model. Dengan nilai R^2 sebesar 0.7661, model ini hanya mampu menjelaskan sekitar 76.61% variabilitas data. Nilai MSE sebesar 20.2689 dan RMSE sebesar 4.5021 berarti rata-rata kesalahan prediksi model ini sekitar 4.5 tahun dari nilai aktual. Performa yang rendah ini mengindikasikan bahwa hubungan antara fitur-fitur dengan variabel target bersifat kompleks dan tidak sepenuhnya linear. Model linear sederhana tidak mampu menangkap pola non-linear dan interaksi antar fitur yang mungkin ada. Hal ini juga terlihat dari MAE sebesar 3.1866 yang merupakan yang tertinggi di antara keempat model.

2. *Decision Tree Regressor*

Model ini menunjukkan peningkatan yang signifikan dibandingkan *Linear Regression*. Dengan R^2 sebesar 0.8934, model ini mampu menjelaskan hampir 89.34% variabilitas data. MSE turun menjadi 9.2347 dan RMSE turun menjadi 3.0389, yang berarti rata-rata kesalahan prediksi sekitar 3 tahun. MAE sebesar 1.6784 juga menunjukkan peningkatan yang signifikan. Peningkatan ini menunjukkan bahwa model berbasis pohon keputusan mampu menangkap pola non-linear dan interaksi antar fitur dengan lebih baik. Namun, Decision Tree memiliki kecenderungan untuk overfitting terhadap data *training*

karena strukturnya hanya satu pohon, yang tercermin dari masih cukup tingginya nilai MSE dan RMSE dibandingkan model ensemble.

3. *Random Forest Regressor*

Model ini menunjukkan performa yang sangat baik dengan R^2 sebesar 0.9622, yang berarti model ini mampu menjelaskan 96.22% variabilitas data. MSE turun drastis menjadi 3.2791 dan RMSE turun menjadi 1.8108, dengan MAE hanya 1.1443 tahun. Random Forest, sebagai model ensemble yang menggabungkan banyak pohon keputusan, berhasil mengatasi kelemahan *overfitting* pada Decision Tree. Dengan menggabungkan prediksi dari banyak pohon yang dibangun pada subset data dan fitur yang berbeda, model ini menjadi lebih stabil dan akurat. Penurunan MSE dari 9.2347 (*Decision Tree*) menjadi 3.2791 (*Random Forest*) menunjukkan peningkatan yang sangat signifikan.

4. *XGBoost Regressor*

Model ini menunjukkan performa terbaik di antara keempat model dengan R^2 sebesar 0.9652, menjelaskan 96.52% variabilitas data. MSE terendah yaitu 3.0155 dan RMSE terendah yaitu 1.7365, hanya sedikit lebih baik dari *Random Forest*. MAE sebesar 1.1959 juga menunjukkan tingkat akurasi yang sangat baik. XGBoost, sebagai model *boosting*, bekerja secara iteratif untuk memperbaiki kesalahan dari model sebelumnya, sehingga mampu mencapai performa yang sangat tinggi. Meskipun nilai MSE dan RMSE XGBoost sedikit lebih rendah dari Random Forest, perbedaannya tidak terlalu besar, menunjukkan bahwa kedua model ensemble ini sangat kompetitif.

Berdasarkan perbandingan keempat metrik tersebut, model XGBoost Regressor menunjukkan performa terbaik dengan nilai R^2 tertinggi (0.9652), RMSE terendah (1.7365), MSE terendah (3.0155), dan MAE yang sangat baik (1.1959).

4.9 Hyperparameter Tuning

Hyperparameter tuning dilakukan pada model XGBoost Regressor menggunakan metode GridSearchCV dengan validasi silang 5-fold. Tujuannya adalah untuk menemukan kombinasi parameter yang optimal agar model mencapai performa terbaik. Parameter-parameter yang diuji dalam GridSearchCV adalah sebagai berikut:

Tabel 4.4 Parameter pada Hyperparameter Tuning

Parameter	Nilai yang Diuji
n_estimators	100, 200, 300
max_depth	3, 5, 7
learning_rate	0.01, 0.1, 0.2
subsample	0.7, 0.8, 1.0
colsample_bytree	0.7, 0.8, 1.0

Setelah dilakukan GridSearchCV dengan total 243 kombinasi parameter ($3 \times 3 \times 3 \times 3 \times 3$) dan validasi silang 5-fold, ditemukan parameter terbaik sebagai berikut:

Tabel 4.5 Parameter terbaik pada Hyperparameter Tuning

Parameter	Nilai Terbaik
colsample_bytree	0.7
learning_rate	0.1
max_depth	7
n_estimators	300
subsample	0.7

Metrik evaluasi untuk model XGBoost Regressor yang telah melalui proses hyperparameter tuning disajikan dalam tabel berikut.

Tabel 4.5 Matriks evaluasi pada model XGBoost Regressor Hyperparameter Tuning

Model XGBoost	MAE	MSE	RMSE	R ²
Tuned	1.0905	2.6707	1.6342	0.9692

Model XGBoost Regressor yang telah melalui proses hyperparameter tuning menunjukkan performa yang sangat baik dengan nilai R^2 sebesar 0.9692, yang berarti model mampu menjelaskan 96.92% variabilitas data dan hanya sekitar 3.08% variasi yang tidak dapat dijelaskan. MSE sebesar 2.6707 mengindikasikan bahwa model tidak membuat kesalahan prediksi yang ekstrem, sementara RMSE sebesar 1.6342 berarti rata-rata kesalahan prediksi model ini sekitar 1.63 tahun dari nilai aktual Angka Harapan Hidup, yang dalam rentang data 36.3 hingga 89.0 tahun menunjukkan tingkat akurasi yang sangat tinggi. MAE sebesar 1.0905 menegaskan bahwa secara rata-rata absolut, prediksi model hanya meleset sekitar 1.09 tahun dari nilai sebenarnya, yang menunjukkan konsistensi model dalam menghasilkan prediksi yang akurat tanpa kesalahan sistematis yang besar.

4.10 Pemilihan Model Final

Tabel 4.5 Matriks evaluasi pada model XGBoost Regressor Hyperparameter Tuning

Model XGBoost	MAE	MSE	RMSE	R^2
Non-Tuned	1.1959	3.0155	1.7365	0.9652
Tuned	1.0905	2.6707	1.6342	0.9692


Model XGBoost Regressor yang telah melalui proses hyperparameter tuning menunjukkan performa terbaik di antara keempat model dengan R^2 sebesar 0.9692, menjelaskan 96.92% variabilitas data. MSE terendah yaitu 2.6707 dan RMSE terendah yaitu 1.6342, lebih baik dibandingkan versi non-tuned maupun model lainnya. MAE sebesar 1.0905 juga menunjukkan tingkat akurasi yang sangat baik. XGBoost, sebagai model boosting, bekerja secara iteratif untuk memperbaiki kesalahan dari model sebelumnya, sehingga mampu mencapai performa yang sangat tinggi. Proses hyperparameter tuning yang dilakukan dengan GridSearchCV berhasil menemukan kombinasi parameter optimal, yaitu `max_depth=7`, `learning_rate=0.1`, `n_estimators=300`, `subsample=0.7`, dan `colsample_bytree=0.7`, yang memungkinkan model menangkap pola yang lebih kompleks sekaligus mencegah overfitting. Meskipun nilai MSE dan RMSE XGBoost setelah tuning sedikit lebih rendah dari Random Forest, perbedaannya menunjukkan bahwa optimasi

parameter berhasil meningkatkan performa model secara signifikan, menjadikannya model terbaik untuk memprediksi Angka Harapan Hidup pada dataset ini.

4.11 Interpretasi Model

Interpretasi model dilakukan pada model terbaik, yaitu XGBoost Regressor yang telah di-*tune*. Analisis interpretasi menggunakan dua pendekatan, yaitu Feature Importance dan SHAP (*SHapley Additive exPlanations*), yang saling melengkapi untuk memberikan pemahaman komprehensif tentang kontribusi dan arah pengaruh setiap fitur.

1. *Feature Importance* (Tuned XGBoost)




Gambar 4.10 *Feature Importance* model akhir

Berdasarkan analisis *feature importance* dari model XGBoost yang telah di-*tune*, fitur Income composition of resources menjadi prediktor paling berkontribusi. Fitur ini mencerminkan indeks komposisi pendapatan dan sumber daya suatu negara, yang erat kaitannya dengan tingkat kesejahteraan ekonomi dan pembangunan manusia. Semakin tinggi indeks ini, semakin baik akses masyarakat terhadap layanan kesehatan, pendidikan, dan kebutuhan dasar lainnya.

Fitur Adult Mortality menempati posisi kedua, menunjukkan bahwa tingkat kematian dewasa merupakan faktor kesehatan yang sangat signifikan dalam menentukan Angka Harapan Hidup. Tingkat kematian dewasa yang tinggi mengindikasikan buruknya layanan kesehatan, tingginya prevalensi penyakit, atau adanya faktor-faktor risiko kesehatan yang signifikan pada populasi usia produktif. Fitur-fitur lain yang juga memberikan kontribusi penting adalah under-five deaths, Diphtheria, thinness 1-19 years, dan Schooling. Kehadiran fitur imunisasi (Diphtheria, Polio, Hepatitis B) dan indikator gizi (BMI, thinness) menunjukkan bahwa intervensi kesehatan dasar dan status gizi memiliki peran penting dalam menentukan umur panjang suatu populasi. Sementara itu, fitur Measles dan GDP memberikan kontribusi yang relatif kecil dibandingkan fitur-fitur lainnya.

2. Analisis SHAP (SHapley Additive exPlanations)



Gambar 4.10 Plot SHAP model akhir

Analisis SHAP memberikan wawasan yang lebih mendalam tentang arah pengaruh setiap fitur terhadap prediksi. Berdasarkan SHAP summary plot dari model XGBoost yang telah di-tune, berikut adalah interpretasi dari fitur-fitur yang paling berpengaruh. Adult Mortality (Pengaruh Negatif) memiliki rentang dampak SHAP yang paling luas dan menjadi fitur teratas dalam SHAP summary plot. Nilai Adult Mortality yang tinggi cenderung memiliki nilai SHAP negatif yang besar, yang berarti tingkat kematian dewasa yang tinggi sangat menurunkan prediksi Angka Harapan Hidup. Sebaliknya, tingkat Adult Mortality yang rendah cenderung memiliki nilai SHAP positif yang meningkatkan prediksi. Hubungan ini sangat logis karena ketika banyak orang meninggal pada usia produktif (15-60 tahun), rata-rata Angka Harapan Hidup secara keseluruhan akan menurun drastis.

Income composition of resources (Pengaruh Positif) menunjukkan dampak positif yang kuat terhadap Angka Harapan Hidup. Nilai indeks yang tinggi mendorong prediksi Angka Harapan Hidup lebih tinggi, sedangkan nilai rendah menurunkannya. Hal ini karena indeks komposisi pendapatan dan sumber daya mencerminkan tingkat pendapatan, distribusi kekayaan, dan akses terhadap sumber daya ekonomi di suatu negara. Negara dengan indeks yang tinggi cenderung memiliki infrastruktur kesehatan yang lebih baik, akses terhadap makanan bergizi, pendidikan yang lebih baik, dan lingkungan yang lebih sehat. Under-five deaths (Pengaruh Negatif) menunjukkan dampak negatif yang substansial terhadap Angka Harapan Hidup. Tingkat kematian balita yang tinggi sangat mengurangi prediksi Angka Harapan Hidup. Hal ini mencerminkan bahwa kegagalan dalam melindungi anak-anak dari kematian dini yang sering disebabkan oleh penyakit yang dapat dicegah, kekurangan gizi, atau kurangnya akses terhadap layanan kesehatan dasar berdampak buruk pada statistik harapan hidup secara keseluruhan.

Schooling (Pengaruh Positif) menunjukkan dampak positif yang jelas terhadap Angka Harapan Hidup. Nilai Schooling yang tinggi (rata-rata tahun bersekolah yang lebih tinggi) cenderung meningkatkan prediksi Angka Harapan Hidup. Pendidikan berperan dalam meningkatkan kesadaran akan kesehatan, akses terhadap informasi, kemampuan untuk membuat keputusan kesehatan yang lebih baik, dan peningkatan pendapatan, yang semuanya berkontribusi pada umur yang lebih panjang. Thinness 1-19 years (Pengaruh Negatif) pada anak dan remaja menunjukkan dampak negatif terhadap Angka Harapan Hidup, di mana nilai tinggi cenderung menurunkan prediksi. Hal ini mencerminkan masalah gizi kronis yang

dimulai sejak masa kanak-kanak, yang dapat mempengaruhi kesehatan dan produktivitas di masa dewasa. Imunisasi (Diphtheria, Polio, Hepatitis B) menunjukkan pengaruh positif terhadap Angka Harapan Hidup, di mana cakupan imunisasi yang lebih tinggi berkontribusi pada peningkatan prediksi. Hal ini menegaskan pentingnya program imunisasi dalam mencegah penyakit menular yang mematikan, terutama pada anak-anak.

4.12 Pembahasan

Model XGBoost Regressor yang telah di-*tune* berhasil memprediksi Angka Harapan Hidup dengan akurasi yang sangat tinggi ($R^2 = 0.9692$). Hal ini menunjukkan bahwa kombinasi fitur-fitur yang terdapat dalam dataset, terutama yang berkaitan dengan ekonomi, pendidikan, dan kesehatan dasar, sangat menentukan umur panjang suatu populasi. Dengan rata-rata kesalahan prediksi hanya sekitar 1.63 tahun (RMSE), model ini dapat diandalkan sebagai alat prediksi dan analisis faktor-faktor penentu Angka Harapan Hidup. Hasil ini juga membuktikan bahwa machine learning, khususnya model *ensemble boosting*, sangat efektif untuk menangkap pola kompleks dan interaksi antar fitur yang tidak dapat dijelaskan oleh model statistik sederhana seperti *Linear Regression* ($R^2 = 0.7661$). Kemampuan XGBoost dalam menangani data dengan *outlier* dan pola *non-linear* menjadi keunggulan utamanya.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat diperoleh beberapa kesimpulan sebagai berikut.

1. Berdasarkan analisis Feature Importance dan SHAP pada model XGBoost Regressor yang telah di-tuning, faktor yang paling berpengaruh terhadap *Life Expectancy* adalah Income Composition of Resources. Variabel ini menunjukkan kontribusi terbesar dalam model dan memiliki pengaruh positif terhadap peningkatan angka harapan hidup. Selain itu, variabel Adult Mortality, under-five deaths, Schooling, serta indikator kesehatan seperti Diphtheria, Polio, dan Hepatitis B juga memiliki pengaruh yang signifikan terhadap prediksi angka harapan hidup. Hasil analisis SHAP menunjukkan bahwa tingginya nilai Income Composition of Resources dan Schooling cenderung meningkatkan angka harapan hidup, sedangkan tingginya Adult Mortality dan under-five deaths cenderung menurunkan angka harapan hidup.
2. Model regresi yang dihasilkan memiliki tingkat akurasi yang sangat baik. Model terbaik, yaitu XGBoost Regressor yang telah melalui proses hyperparameter tuning, memperoleh nilai R^2 sebesar 0,9692 dan RMSE sebesar 1,6342. Hasil tersebut menunjukkan bahwa model mampu menjelaskan sekitar 96,92% variasi data *Life Expectancy*, sedangkan rata-rata kesalahan prediksi hanya sekitar 1,63 tahun dari nilai aktual. Dengan demikian, model yang dibangun memiliki kemampuan prediksi yang sangat tinggi dan dapat digunakan untuk memprediksi angka harapan hidup secara akurat.
3. Berdasarkan perbandingan empat algoritma regresi yang digunakan, yaitu Linear Regression, Decision Tree Regressor, Random Forest Regressor, dan XGBoost Regressor, model yang memberikan performa terbaik adalah XGBoost Regressor yang telah melalui proses hyperparameter tuning. Model ini menghasilkan nilai MAE, MSE, dan RMSE paling rendah serta nilai R^2 paling tinggi dibandingkan model lainnya. Hasil tersebut menunjukkan bahwa XGBoost Regressor lebih mampu menangkap hubungan nonlinier dan pola kompleks antarvariabel dibandingkan model

regresi lainnya sehingga menjadi model yang paling optimal untuk memprediksi angka harapan hidup pada dataset yang digunakan.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya.

1. Saran Pengembangan Model

Penelitian selanjutnya dapat melakukan hyperparameter tuning pada model lain seperti Random Forest Regressor dan Decision Tree Regressor sehingga dapat diketahui apakah performanya dapat ditingkatkan lebih jauh. Selain itu, dapat dicoba berbagai metode penanganan outlier, seperti winsorizing, capping, atau penghapusan outlier tertentu untuk melihat pengaruhnya terhadap performa model prediksi.

2. Saran Pengumpulan Data

Kualitas data dapat ditingkatkan dengan melengkapi variabel yang masih memiliki jumlah *missing value* cukup besar, seperti Population, Hepatitis B, dan GDP. Selain itu, penggunaan data dengan periode yang lebih terbaru juga disarankan agar model dapat merepresentasikan kondisi kesehatan dan sosial ekonomi yang lebih mutakhir.

3. Saran untuk Penelitian Selanjutnya

Penelitian berikutnya dapat melakukan analisis khusus terhadap pengaruh HIV/AIDS terhadap angka harapan hidup tanpa menghapus variabel tersebut dari dataset, sehingga dapat diperoleh pemahaman yang lebih mendalam mengenai dampaknya. Selain itu, penelitian juga dapat membandingkan hasil model menggunakan dataset dari sumber lain atau menerapkan algoritma machine learning yang lebih modern untuk melihat potensi peningkatan akurasi prediksi.

LAMPIRAN

LAMPIRAN 1. Repository GitHub

<https://github.com/armeldawardhani/Project-Machine-Learning.git>

LAMPIRAN 2. Sumber Dataset

<https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who>

LAMPIRAN 3. Riwayat Penggunaan AI

<https://chat.deepseek.com/share/raaalxavfg7k1rovcn>

<https://claude.ai/share/cfae0177-c917-44b4-9450-b6cdbe921f0b>