

PREDIKSI ANGKA HARAPAN HIDUP (LIFE EXPECTANCY) MENGUNAKAN PENDEKATAN MACHINE LEARNING REGRESI

Presented by | Date
KELOMPOK D | 12th February 2030




KELOMPOK D



LATAR BELAKANG

Distribusi Status Negara



82,6% Developing 17,4% Developed
(n = 2.938)

- Harapan hidup adalah indikator utama kesejahteraan, kesehatan, dan pembangunan sosial-ekonomi suatu negara
- Meski tren global meningkat, kesenjangan antarnegara masih sangat besar, terutama Developing vs Developed
- Data WHO 193 negara (2000–2015): rata-rata 69,22 tahun, kisaran 36,3 – 89,0 tahun
- Pendekatan Machine Learning memungkinkan prediksi kuantitatif berbasis 22 faktor kesehatan, ekonomi & sosial

Tujuan dan Manfaat

Manfaat

- 01 Teoretis, Memperkaya literatur di bidang machine learning dan kesehatan masyarakat, sekaligus menjadi referensi metodologis bagi peneliti lain dalam memilih model regresi (Linear, Decision Tree, Random Forest, XGBoost) untuk studi prediktif serupa.
- 02 Praktis, Menghasilkan model prediktif angka harapan hidup berbasis faktor demografis yang dapat dimanfaatkan pemerintah, institusi kesehatan, dan praktisi data sebagai dasar pengambilan keputusan dan perencanaan intervensi kesehatan yang lebih terarah.

Tujuan

- 01 Mengetahui faktor-faktor yang paling berpengaruh terhadap angka harapan hidup berdasarkan dataset Life Expectancy Data.
- 02 Mengukur kemampuan model regresi dalam memprediksi angka harapan hidup berdasarkan variabel-variabel yang tersedia dalam dataset.
- 02 Menentukan model regresi terbaik di antara Regresi Linear, Decision Tree Regressor, Random Forest Regressor, dan XGBoost Regressor dalam memprediksi angka harapan hidup.

DATASET



2.938

**Total Baris
(Observasi)**

22

**Total Baris
(Variabel Awal)**

193

**Negara
(Seluruh Dunia)**

16 Tahun

**Periode
(2000-2015)**


Sumber dan Seleksi Data

- Sumber: WHO & United Nations, publik di Kaggle
- Target : Life expectancy (float, kontinu)
- Tipe data : 1 kategorik, 3 int64, 16 float64
- Dihapus dari model: Country, Year (identitas), Status, percentage expenditure, thinness 5-9y, infant deaths, HIV/AIDS
- Fitur final untuk pemodelan: 14 fitur

Variabel Prediktor :

- KESEHATAN : Adult Mortality, BMI, Hepatitis B, Polio, Diphtheria
- PENYAKIT : Measles, under-five deaths, thinness 1-19 years
- EKONOMI : GDP, Alcohol, Total expenditure, Population
- SOSIAL : Income composition of resources, Schooling

Alur Penelitian



EDA

Bar chart distribusi Status → Histogram 19 fitur → Boxplot outlier → Scatter plot tiap fitur vs target → Heatmap korelasi

Data Cleaning

Imputasi median (14 kolom) → Verifikasi 0 duplikat → Deteksi outlier IQR → Outlier dipertahankan (mencerminkan kondisi nyata)


Seleksi Fitur

Label Encoding Status → Heatmap multikolinearitas → Drop 3 fitur → XGBoost Feature Importance (2 tahap) + SHAP → Drop HIV/AIDS


Modeling & Eval

Standardisasi → Split 80:20 → Latih 4 model → Evaluasi MAE/MSE/RMSE/ R^2 → GridSearchCV Tuning XGBoost → Pilih model final

Eksplorasi Data, Distribusi & Histogram



- 2.426 Developing (82,6%)
- 512 Developed (17,4%)
- Ketidakseimbangan kelas signifikan




- Normal/unimodal : Life expectancy, BMI, Schooling
- Right-skewed : infant deaths, Measles, HIV/AIDS, GDP, Population → banyak outlier ekstrem

Eksplorasi Data, Boxplot & Deteksi Outlier


Temuan Outlier (Metode IQR)

- Hampir SEMUA fitur memiliki outlier signifikan
- Outlier terbanyak: HIV/AIDS & Measles (542 masing-masing)
- Status: 512 outlier (karena encoding 0/1)
- under-five deaths: 394, percentage expenditure: 389, Hepatitis B: 322
- Satu-satunya tanpa outlier: BMI
- Keputusan: outlier DIPERTAHANKAN, mencerminkan kondisi nyata negara dengan beban penyakit tinggi




Eksplorasi Data, Scatter Plot & Korelasi

Scatter Plot : Fitur vs Life Expectancy



- Adult Mortality → korelasi negatif kuat
- Income composition & Schooling → positif kuat

Heatmap Matriks Korelasi



- Income composition $r=0,80 \uparrow$; Schooling $r=0,75 \uparrow$; Adult Mortality $r=-0,70 \downarrow$
- Multikolinearitas: thinness 1-19y & 5-9y ($r=0,94$), infant deaths & under-5 ($r \approx 1,00$)

Validasi & Pembersihan Data





- Duplikat: 0 baris duplikat ditemukan
- Nilai negatif: 0, semua fitur numerik bersih
- Dimensi dataset: (2938, 20) setelah drop Country & Year
- Missing value tertinggi:
Population: 652 | Hepatitis B: 553
GDP: 448 | Total expenditure: 226
Alcohol: 194 | Income composition: 167
Schooling: 163 | BMI/thinness: 34 masing-masing
Life expectancy & Adult Mortality: 10

Pembersihan & Imputasi

- Metode: Imputasi MEDIAN pada 14 kolom numerik
- Alasan median > mean: banyak distribusi right-skewed & mengandung outlier ekstrem
- Hasil: semua 2.938 baris menjadi non-null (0 missing value tersisa)
- Boxplot setelah imputasi → outlier masih ada, terbukti bukan artefak missing value
- Deteksi outlier IQR → hitung jumlah saja, tidak dihapus



Feature Importance & SHAP — Tahap 1 (dengan HIV/AIDS)

1. Label Encoding : Status → 0/1
 2. Heatmap korelasi → deteksi multikolinearitas → hapus 3 fitur:
 - percentage expenditure
 - thinness 5-9 years ($r=0,94$ dng 1-19y)
 - infant deaths ($r\approx 1,00$ dng under-5)
 3. XGBoost Feature Importance (gain)
- Tahap 1
4. SHAP (TreeExplainer) Tahap 1
 5. HIV/AIDS mendominasi ekstrem → akan di-drop untuk Tahap 2



Feature Importance & SHAP — Tahap 2 (Tanpa HIV/AIDS)

- HIV/AIDS mendominasi dengan skor gain 0,7568, jauh di atas fitur lain
- Kehadirannya menutupi (confounding) kontribusi fitur penting lainnya
- Setelah di-drop, model lebih seimbang & interpretatif untuk kebijakan
- Perubahan ranking setelah drop:
 - ① Income composition: 0,6466 (naik jadi #1)
 - ② Adult Mortality: 0,2134
 - ③ under-five deaths: 0,0431
 - ④ Diphtheria: 0,0185
 - ⑤ thinness 1-19 years: 0,0185
 - ⑥ Schooling: 0,0134



Evaluasi & Perbandingan



Model	R2	MAE	MSE	RMSE
Linear Regression	0.7661	3.1866	20.2689	4.5021
Decision Tree	0.8934	1.6784	9.2347	3.0389
Random Forest	0.9622	1.1443	3.2791	1.8108
XGBoost	0.9652	1.1959	3.0155	1.7365

Pemodelan — 4 Algoritma Regresi

- **Linear Regression**, Hubungan linear sederhana. Digunakan sebagai acuan pembandingan, menganggap semua fitur berkontribusi secara linier ke target.

- **Decision Tree**, Partisi rekursif data berdasarkan nilai fitur. Mampu menangkap pola non-linear & interaksi tanpa asumsi distribusi.

- **Random Forest**, Ratusan decision tree dilatih secara paralel (bagging). Rata-rata prediksi mengurangi variance & mencegah overfitting.

- **XGBoost**, Pohon dibangun sekuensial, tiap pohon memperbaiki error pohon sebelumnya. Efisien, akurasi tinggi, digunakan untuk tuning.

Setup Pemodelan

- Train-test split 80:20 (random_state=42)
- $X_{\text{train}} : 2.350 \times 14$
- $X_{\text{test}} : 588 \times 14$
- Fitur distandardisasi (mean=0, std=1)
- Semua model diuji pada data uji identik
- Metrik : MAE, MSE, RMSE, R^2

Model Final Terpilih

XGBoost Regressor (Tuned)

0.9692

R-squared

96,92% variansi dijelaskan

1.09 tahun

MAE

rata-rata error prediksi

1.63 tahun

RMSE

root mean squared error

+20,3%

vs Linear Reg.

peningkatan R^2 dari 0.766

Parameter Terbaik (GridSearchCV): $\text{max_depth}=7 \cdot \text{n_estimators}=300 \cdot \text{learning_rate}=0.1 \cdot \text{subsample}=0.7 \cdot \text{colsample_bytree}=0.7$

① Faktor Terkuat

Income composition (64,66%) & Adult Mortality (21,34%) — faktor ekonomi-sosial dominan terhadap harapan hidup

② Performa Unggul

XGBoost Tuned terbaik: $R^2=0,9692$, $\text{MAE}=1,09$ tahun — jauh di atas Linear Regression ($R^2=0,7661$, $\text{MAE}=3,19$)

③ Temuan HIV/AIDS

HIV/AIDS confounding factor — setelah di-drop, model lebih interpretatif untuk rekomendasi kebijakan kesehatan

Kesimpulan

1

Faktor Paling Berpengaruh

Berdasarkan Feature Importance dan SHAP, faktor dominan adalah **Income Composition of Resources** (pengaruh positif). Variabel lain yang signifikan: Schooling, Diphtheria, Polio, Hepatitis B (meningkatkan), serta Adult Mortality dan Under-five Deaths (menurunkan) angka harapan hidup.

2

Akurasi Model

Model terbaik (XGBoost Regressor setelah hyperparameter tuning) menghasilkan **$R^2 = 0,9692$** dan **RMSE = 1,6342**. artinya model mampu menjelaskan ~96,92% variasi data dengan rata-rata kesalahan hanya ~1,63 tahun.

3

Model Terbaik

Dari empat algoritma yang diuji (Linear Regression, Decision Tree, Random Forest, XGBoost), **XGBoost Regressor** menghasilkan performa terbaik MAE, MSE, RMSE paling rendah dan R^2 paling tinggi karena kemampuannya menangkap pola nonlinier antarvariabel.